



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

توسعه دستیار پزشکی فارسی مبتنی بر مدل‌های زبانی بزرگ

Persian Medical Assistant Development Based on Large
Language Models

استاد راهنما:

دکتر حمیدرضا برادران

پژوهشگر:

سید محمدحسین هاشمی

شهریور ۱۴۰۴

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

توسعه دستیار پزشکی فارسی مبتنی بر مدل‌های زبانی بزرگ

Persian Medical Assistant Development Based on Large
Language Models

استاد راهنما:

دکتر حمیدرضا برادران

پژوهشگر:

سید محمدحسین هاشمی

شهریور ۱۴۰۴

چکیده

با رشد چشمگیر فناوری‌های هوش مصنوعی و مدل‌های زبانی بزرگ^۱، توسعه دستیارهای هوشمند تخصصی دوزبانه که قادر به ارائه پاسخ‌های دقیق، امن و مبتنی بر دانش معتبر باشند، به یکی از نیازهای اساسی در حوزه پزشکی تبدیل شده است. این پژوهش با هدف طراحی و پیاده‌سازی یک دستیار هوشمند جامع پزشکی به دو زبان فارسی و انگلیسی، از ترکیب سه تکنیک پیشرفته در پردازش زبان طبیعی بهره گرفته است.

در مرحله اول، چهار مدل زبانی شامل Gemma-3-12B، Gemma-2-9B، Aya-expense-8b و gpt-oss-20b مورد ارزیابی قرار گرفتند. مدل **Gemma-3-12B-IT** به دلیل عملکرد برتر با میانگین دقت 69.7% به عنوان مدل اصلی انتخاب شد. این مدل ابتدا با استفاده از روش Supervised Fine-Tuning و تکنیک LoRA (با پیکربندی بهینه $\text{rank}=32$ و $\alpha=32$) بر روی 200,000 نمونه داده تخصصی پزشکی انگلیسی از مجموعه UltraMedical تنظیم دقیق شد که منجر به تولید مدل gemma-3-12b-it-en-sft با بهبود 7.6% در معیارهای ارزیابی گردید [۱].

در ادامه، برای پشتیبانی از زبان فارسی، دو مدل gpt-oss-20b و Gemma-3-12b-it با 22,000 نمونه از دیتاست MF3QA (با $\text{LoRA rank}=4$ و $\alpha=8$) آموزش داده شدند. مدل gemma-3-12b-it-fa-sft با میانگین دقت 70.8% به عنوان مدل برتر فارسی انتخاب شد که در مقایسه با مدل‌های موجود فارسی نظیر PersianMind (با دقت 25.7%) و Qwen2.5 (با دقت 45.5%)، عملکرد بسیار برتری نشان داد.

در مرحله دوم، سیستم بازیابی افزوده^۲ دوزبانه پیاده‌سازی شد. برای منابع انگلیسی، 373,500 سند از StatePearls و Textbooks با استفاده از تکنیک نوآورانه Late Chunking پردازش شدند که بهبود 15-20% در دقت بازیابی را نسبت به روش‌های سنتی ارائه دادند [۲]. برای زبان فارسی، دیتاست Persian Medical Corpus با کتابخانه Hazm پیش‌پردازش و به 5,176,679 تکه تقسیم شد. این سیستم دوزبانه با مجموع 5.55 میلیون تکه اطلاعاتی، بهبود 1.09% برای مدل انگلیسی و 1.2% برای مدل فارسی را محقق کرد [۳].

در مرحله سوم، به منظور تضمین امنیت و کیفیت پاسخ‌ها، سیستم Guardrails با معماری دولایه برای کنترل ورودی‌ها و خروجی‌ها طراحی شد. این سیستم قابلیت شناسایی و فیلتر محتوای نامناسب پزشکی را فراهم کرد [۴].

ارزیابی‌های نهایی نشان می‌دهد که سیستم یکپارچه توسعه‌یافته، بهبود میانگین 6.73% برای انگلیسی (از 70.54% به 77.27%) و 3.2% برای فارسی (از 68.8% به 72%) را در معیارهای استاندارد پزشکی نظیر MedQA (10.36% بهبود)، HeadQA (7.86% بهبود) و MMLU پزشکی تجربه کرده است. علی‌رغم افزایش 176% در زمان پاسخ‌دهی به دلیل لایه‌های امنیتی، سیستم قادر به ارائه پاسخ‌های دقیق، مستند و امن به دو زبان فارسی و انگلیسی است.

^۱Large Language Models

^۲Retrieval-Augmented Generation

این پژوهش نشان می‌دهد که ترکیب هوشمندانه تکنیک‌های Guardrails و RAG، Fine-tuning می‌تواند راه‌حلی جامع برای توسعه دستیارهای هوشمند پزشکی دوزبانه ارائه دهد. سیستم توسعه‌یافته کاربردهای گسترده‌ای در مراکز درمانی، آموزش پزشکی، مشاوره سلامت آنلاین و تحقیقات بالینی دارد و گامی مؤثر در راستای دموکراتیزه‌سازی دسترسی به اطلاعات پزشکی معتبر در جوامع فارسی و انگلیسی‌زبان محسوب می‌شود.

کلمات کلیدی: مدل‌های زبانی بزرگ، تنظیم دقیق نظارت‌شده، بازیابی افزوده، مکانیزم‌های امنیتی، پردازش زبان طبیعی پزشکی، سیستم‌های دوزبانه فارسی-انگلیسی

فهرست مطالب

۱	مقدمه	۱
۱	۱.۱ هدف پروژه	۱.۱
۲	۲.۱ ساختار دوگانه پروژه	۲.۱
۲	۳.۱ ساختار گزارش	۳.۱
۳	۲ مطالعات انجام شده	۲
۳	۱.۲ رویکردهای دوگانه: انگلیسی با پشتیبانی فارسی و مسیر اختصاصی فارسی	۱.۲
۳	۲.۲ مدل‌های زبانی بزرگ تخصصی پزشکی	۲.۲
۳	۱.۲.۲ معماری‌های پایه	۱.۲.۲
۴	۲.۲.۲ مدل‌های تخصصی پزشکی	۲.۲.۲
۴	۳.۲ تکنیک‌های تنظیم دقیق (Fine-Tuning)	۳.۲
۴	۱.۳.۲ Supervised Fine-Tuning	۱.۳.۲
۴	۲.۳.۲ تکنیک‌های بهینه‌سازی منابع محاسباتی	۲.۳.۲
۵	۴.۲ سیستم‌های بازیابی اطلاعات (RAG)	۴.۲
۵	۱.۴.۲ مفاهیم بنیادی RAG	۱.۴.۲
۵	۲.۴.۲ تکنیک‌های پیشرفته RAG	۲.۴.۲
۵	۳.۴.۲ تکنیک‌های چانکینگ و پردازش	۳.۴.۲
۵	۴.۴.۲ کاربردهای RAG در پزشکی	۴.۴.۲
۵	۵.۲ مطالعات مرتبط با زبان فارسی	۵.۲
۶	۶.۲ تکنیک‌های استدلال پیشرفته	۶.۲
۶	۱.۶.۲ Prompting Chain-of-Thought	۱.۶.۲
۶	۲.۶.۲ روش‌های استدلال توسعه‌یافته	۲.۶.۲
۶	۳.۶.۲ Prompt Engineering در حوزه پزشکی	۳.۶.۲
۶	۷.۲ مکانیزم‌های امنیتی (Guardrails)	۷.۲
۶	۱.۷.۲ NeMo Guardrails	۱.۷.۲
۶	۲.۷.۲ الگوهای امنیتی تخصصی	۲.۷.۲
۷	۸.۲ تکنیک‌های تنظیم ترجیحات	۸.۲
۷	۱.۸.۲ آموزش با بازخورد انسانی	۱.۸.۲
۷	۲.۸.۲ روش‌های بهینه‌سازی ترجیح	۲.۸.۲
۷	۹.۲ مجموعه داده‌ها و معیارهای ارزیابی	۹.۲
۷	۱.۹.۲ مجموعه داده‌های تخصصی پزشکی	۱.۹.۲
۷	۲.۹.۲ معیارهای ارزیابی استاندارد	۲.۹.۲
۷	۳.۹.۲ ابزارهای ارزیابی	۳.۹.۲

۷	۱۰.۲	مدل‌های چندزبانه
۷	۱.۱۰.۲	توسعه قابلیت‌های چندزبانه
۸	۲.۱۰.۲	چالش‌های محیط‌های دوزبانه
۸	۱۱.۲	ابزارهای مورد استفاده
۸	۱۲.۲	خلاصه و جمع‌بندی
۹	۳	تنظیم دقیق نظارت‌شده (Supervised Fine-Tuning)
۹	۱.۳	مقدمه
۱۰		اول آموزش با داده‌های انگلیسی
۱۱	۲.۳	انتخاب و آماده‌سازی مجموعه داده‌های آموزشی انگلیسی
۱۱	۱.۲.۳	اهمیت کیفیت داده‌ها در تنظیم دقیق
۱۱	۲.۲.۳	مجموعه داده‌های انگلیسی مورد استفاده برای آموزش
۱۱	۳.۳	ارزیابی اولیه مدل‌های پایه برای آموزش انگلیسی
۱۱	۱.۳.۳	روش‌شناسی ارزیابی
۱۲	۲.۳.۳	مجموعه داده‌های ارزیابی انگلیسی
۱۲	۳.۳.۳	نتایج ارزیابی اولیه مدل‌های پایه
۱۳	۴.۳	آزمون اولیه با پیکربندی پیش‌فرض
۱۳	۱.۴.۳	پیکربندی اولیه
۱۳	۲.۴.۳	نتایج آزمون اولیه
۱۴	۵.۳	بهینه‌سازی پارامترهای LoRA برای آموزش انگلیسی
۱۴	۱.۵.۳	روش‌شناسی آزمون پارامترهای LoRA
۱۴	۲.۵.۳	آزمون پارامترهای مختلف
۱۵	۳.۵.۳	انتقال نتایج به مدل اصلی
۱۵	۶.۳	بهینه‌سازی مجموعه داده‌های انگلیسی
۱۵	۱.۶.۳	فیلترکردن داده‌های کم‌کیفیت
۱۵	۲.۶.۳	معیارهای فیلترکردن
۱۵	۷.۳	آموزش نهایی با داده‌های انگلیسی
۱۵	۱.۷.۳	محدودیت‌های منابع محاسباتی
۱۵	۲.۷.۳	پیکربندی نهایی آموزش انگلیسی
۱۶	۳.۷.۳	افزایش تعداد Epoch
۱۶	۸.۳	ارزیابی نتایج تنظیم دقیق انگلیسی
۱۶	۱.۸.۳	مقایسه عملکرد قبل و بعد از تنظیم دقیق
۱۶	۲.۸.۳	تحلیل نتایج آموزش انگلیسی
۱۸		دوم آموزش با داده‌های فارسی
۱۹	۹.۳	انگیزه و ضرورت آموزش فارسی
۱۹	۱۰.۳	انتخاب مجموعه داده‌های فارسی
۱۹	۱.۱۰.۳	معرفی دیتاست MF3QA
۱۹	۲.۱۰.۳	مجموعه داده‌های ارزیابی فارسی

۱۹	انتخاب مدل‌ها برای آموزش فارسی	۱۱.۳
۱۹	۱.۱۱.۳ معیارهای انتخاب	
۲۰	۲.۱۱.۳ مدل‌های انتخاب شده	
۲۰	۱۲.۳ پیکربندی آموزش فارسی	
۲۱	۱۳.۳ نتایج آموزش مدل‌های فارسی	
۲۱	۱.۱۳.۳ مدل‌های نهایی آموزش داده شده	
۲۱	۲.۱۳.۳ ارزیابی عملکرد مدل‌های فارسی	
۲۱	۳.۱۳.۳ مقایسه با سایر مدل‌های فارسی	
۲۲	۱۴.۳ انتخاب مدل برتر فارسی	
۲۲	۱.۱۴.۳ معیارهای انتخاب	
۲۲	۲.۱۴.۳ مدل برگزیده	
۲۳	۱۵.۳ تحلیل نتایج آموزش فارسی	
۲۳	۱.۱۵.۳ بهبود عملکرد	
۲۳	۲.۱۵.۳ تأثیر پیکربندی LoRA با rank پایین	
۲۳	۱۶.۳ مقایسه جامع آموزش انگلیسی و فارسی	
۲۳	۱۷.۳ جمع‌بندی	

۲۵	۴ پیاده‌سازی سیستم بازیابی افزوده (Retrieval-Augmented Generation)	
۲۵	۱.۴ مقدمه	

۲۶	سوم سیستم RAG با منابع انگلیسی	
۲۷	۲.۴ جمع‌آوری و انتخاب منابع اطلاعاتی انگلیسی	
۲۷	۱.۲.۴ مجموعه داده‌های مرجع MedRAG	
۲۷	۲.۲.۴ مشخصات مجموعه داده‌های انتخابی انگلیسی	
۲۷	۳.۴ روش‌های پردازش و تکه‌تکه‌سازی منابع انگلیسی	
۲۷	۱.۳.۴ استراتژی کلی پردازش داده‌های انگلیسی	
۲۷	۲.۳.۴ پردازش مجموعه داده StatePearls با تکنیک Late Chunking	
۲۸	۳.۳.۴ مزایای تکنیک Late Chunking	
۲۹	۴.۳.۴ پردازش مجموعه داده Textbooks	
۲۹	۵.۳.۴ تنظیمات فنی و پارامترهای انگلیسی	
۲۹	۶.۳.۴ ارزیابی کیفیت تکه‌تکه‌سازی انگلیسی	
۲۹	۴.۴ ذخیره‌سازی و سازماندهی منابع انگلیسی در Elasticsearch	
۲۹	۱.۴.۴ معماری Elasticsearch برای منابع انگلیسی	
۳۰	۲.۴.۴ ساختار ایندکس‌گذاری منابع انگلیسی	
۳۱	۵.۴ ارزیابی عملکرد سیستم RAG انگلیسی	
۳۱	۱.۵.۴ مقایسه عملکرد قبل و بعد از اعمال RAG	
۳۱	۲.۵.۴ تحلیل نتایج و بهبودهای حاصله در سیستم انگلیسی	

۳۳	چهارم سیستم RAG با منابع فارسی و انگلیسی	
۳۴	۶.۴ توسعه سیستم به زبان فارسی	
۳۴	۱.۶.۴ انگیزه و ضرورت توسعه فارسی	

۳۴	۷.۴	جمع‌آوری و انتخاب منابع اطلاعاتی فارسی
۳۴	۱.۷.۴	معرفی دیتاست Persian Medical Corpus
۳۴	۲.۷.۴	مشخصات مجموعه داده‌های فارسی و انگلیسی
۳۴	۸.۴	پردازش و تکه‌تکه‌سازی منابع فارسی
۳۴	۱.۸.۴	پیش‌پردازش با کتابخانه Hazm
۳۵	۲.۸.۴	تکه‌تکه‌سازی Persian Medical Corpus
۳۵	۳.۸.۴	مراحل تکه‌تکه‌سازی فارسی
۳۵	۴.۸.۴	تنظیمات فنی پردازش فارسی
۳۶	۹.۴	محدودیت‌های شباهت‌سنجی در سیستم دوزبانه
۳۶	۱۰.۴	ذخیره‌سازی و سازماندهی منابع دوزبانه
۳۶	۱.۱۰.۴	ساختار ایندکس‌گذاری یکپارچه
۳۷	۱۱.۴	ارزیابی عملکرد سیستم RAG فارسی
۳۷	۱.۱۱.۴	ارزیابی مدل فارسی با سیستم RAG
۳۷	۲.۱۱.۴	نتایج ارزیابی سیستم فارسی
۳۷	۳.۱۱.۴	تحلیل نتایج سیستم دوزبانه
۳۷	۱۲.۴	ارزیابی کیفی سیستم دوزبانه
۳۸	۱۳.۴	تصمیمات طراحی و محدودیت‌ها
۳۸	۱.۱۳.۴	حذف مجموعه داده‌های حجیم
۳۸	۲.۱۳.۴	تأثیر تصمیمات بر عملکرد
۳۸	۱۴.۴	محدودیت‌ها و چالش‌های سیستم دوزبانه
۳۸	۱.۱۴.۴	محدودیت‌های فنی
۳۹	۲.۱۴.۴	چالش‌های الگوریتمی
۳۹	۱۵.۴	پیشنهادهای بهبود
۳۹	۱.۱۵.۴	بهینه‌سازی فنی
۳۹	۲.۱۵.۴	توسعه پایگاه دانش
۳۹	۱۶.۴	تحلیل هزینه-فایده
۳۹	۱.۱۶.۴	هزینه‌های محاسباتی
۴۰	۲.۱۶.۴	مزایای کسب‌شده
۴۰	۱۷.۴	کاربردهای آینده و توسعه‌های ممکن
۴۰	۱.۱۷.۴	یکپارچگی با سیستم‌های بالینی
۴۰	۲.۱۷.۴	توسعه به حوزه‌های تخصصی
۴۰	۱۸.۴	جمع‌بندی

۴۲	۵	پایاده‌سازی مکانیزم‌های امنیتی (Guardrails)
۴۲	۱.۵	مقدمه
۴۲	۲.۵	نیاز به مکانیزم‌های امنیتی در حوزه پزشکی
۴۲	۱.۲.۵	چالش‌های خاص حوزه پزشکی
۴۳	۲.۲.۵	اهمیت پایاده‌سازی Guardrails
۴۳	۳.۵	معماری سیستم Guardrails
۴۳	۱.۳.۵	اجزای کلیدی سیستم
۴۳	۲.۳.۵	نمودار جریان پردازش
۴۳	۳.۳.۵	کنترل ورودی (Input Guardrails)
۴۴	۴.۳.۵	کنترل خروجی (Output Guardrails)

۴۴	۴.۵	پیکربندی سیستم Guardrails
۴۴	۱.۴.۵	تنظیمات اصلی سیستم
۴۴	۲.۴.۵	سیاست‌های امنیتی ورودی
۴۵	۳.۴.۵	سیاست‌های امنیتی خروجی
۴۶	۵.۵	تحلیل سیاست‌های امنیتی
۴۶	۱.۵.۵	سیاست‌های کنترل ورودی
۴۷	۲.۵.۵	سیاست‌های کنترل خروجی
۴۷	۶.۵	چالش‌ها و محدودیت‌ها
۴۷	۱.۶.۵	چالش‌های فنی
۴۷	۲.۶.۵	محدودیت‌های کنونی
۴۸	۷.۵	راهکارهای بهبود
۴۸	۱.۷.۵	بهبودسازی عملکرد
۴۸	۲.۷.۵	افزایش دقت
۴۸	۸.۵	جمع‌بندی
۴۹	۶	نتیجه‌گیری و پیشنهادات
۴۹	۱.۶	خلاصه کلی پروژه
۴۹	۲.۶	دستاوردهای اصلی
۴۹	۱.۲.۶	دستاوردهای آموزش انگلیسی
۴۹	۲.۲.۶	دستاوردهای آموزش فارسی
۵۰	۳.۲.۶	دستاوردهای امنیتی
۵۰	۳.۶	تحلیل نتایج نهایی
۵۰	۱.۳.۶	عملکرد کلی سیستم انگلیسی
۵۰	۲.۳.۶	عملکرد کلی سیستم فارسی
۵۱	۳.۳.۶	تحلیل قوت‌ها و ضعف‌های سیستم
۵۱	۴.۶	کاربردهای عملی
۵۱	۱.۴.۶	کاربردهای بالینی
۵۱	۲.۴.۶	کاربردهای آموزشی
۵۱	۳.۴.۶	کاربردهای پژوهشی
۵۲	۵.۶	پیشنهادهای برای بهبود
۵۲	۱.۵.۶	آموزش مدل به صورت Reinforcement Learning
۵۲	۲.۵.۶	بهبودسازی مکانیزم Guardrails برای سرعت بیشتر
۵۳	۳.۵.۶	Fine-tune مدل Embedder و ارزیابی دقیق‌تر سیستم RAG
۵۴	۴.۵.۶	توسعه پایگاه دانش فارسی
۵۴	۵.۵.۶	پیاده‌سازی Graph RAG
۵۴	۶.۶	تحلیل هزینه-فایده کلی پروژه
۵۴	۱.۶.۶	هزینه‌های صرف‌شده
۵۴	۲.۶.۶	فایده‌های حاصل‌شده
۵۵	۷.۶	نتیجه‌گیری نهایی

فهرست تصاویر

۱.۴	تفاوت Late chunking با روش معمول	۳۰
-----	----------------------------------	----

فهرست جداول

۱۱	مجموعه داده‌های آموزشی انگلیسی مورد استفاده	۱.۳
۱۲	مجموعه داده‌های ارزیابی انگلیسی	۲.۳
۱۲	درصد دقت مدل‌های زبانی بر روی مجموعه داده‌های سوالات چندگزینه‌ای پزشکی انگلیسی	۳.۳
۱۳	پیکربندی اولیه آموزش انگلیسی	۴.۳
۱۳	نتایج آزمون اولیه با پیکربندی پیش‌فرض (LoRA 16-16, 1 epoch)	۵.۳
۱۴	تنظیمات آزمون سریع پارامترهای LoRA	۶.۳
۱۴	نتایج آزمون پارامترهای مختلف LoRA بر روی MedQA	۷.۳
۱۵	مقایسه مجموعه داده اولیه و فیلترشده	۸.۳
۱۶	پیکربندی نهایی آموزش مدل انگلیسی	۹.۳
۱۷	مقایسه عملکرد مدل قبل و بعد از تنظیم دقیق انگلیسی	۱۰.۳
۱۷	مقایسه عملکرد مدل با سایر مدل‌های انگلیسی	۱۱.۳
۱۹	مجموعه داده‌های ارزیابی فارسی	۱۲.۳
۲۰	پیکربندی آموزش مدل Gemma-3-12b-it با داده‌های فارسی	۱۳.۳
۲۱	پیکربندی آموزش مدل gpt-oss-20b با داده‌های فارسی	۱۴.۳
۲۲	دقت مدل‌های آموزش‌دیده فارسی بر روی مجموعه داده‌های تست فارسی	۱۵.۳
۲۲	مقایسه عملکرد مدل‌های فارسی بر روی مجموعه داده‌های MMLU پزشکی	۱۶.۳
۲۳	مقایسه نتایج آموزش انگلیسی و فارسی	۱۷.۳
۲۷	مجموعه داده‌های انگلیسی مورد استفاده در سیستم RAG	۱.۴
۲۹	پارامترهای تکه‌تکه‌سازی برای مجموعه داده‌های انگلیسی	۲.۴
۳۱	مقایسه عملکرد مدل‌های انگلیسی با و بدون سیستم RAG	۳.۴
۳۲	میزان بهبود عملکرد در هر حوزه - سیستم انگلیسی	۴.۴
۳۴	مجموعه داده‌های کامل سیستم RAG دوزبانه	۵.۴
۳۶	پارامترهای تکه‌تکه‌سازی دیتاست فارسی	۶.۴
۳۷	مقایسه عملکرد مدل فارسی با و بدون سیستم RAG	۷.۴
۳۷	میزان بهبود عملکرد در هر حوزه - سیستم فارسی	۸.۴
۵۰	خلاصه عملکرد نهایی سیستم انگلیسی	۱.۶
۵۰	خلاصه عملکرد نهایی سیستم فارسی	۲.۶

فهرست برنامه‌ها

۴۳		معماری سیستم کنترل امنیتی	۱.۵
۴۴		پیکربندی سیستم	۲.۵
۴۴		پرامپت کنترل ورودی	۳.۵
۴۵		پرامپت کنترل خروجی	۴.۵

فصل ۱

مقدمه

در سال‌های اخیر، پیشرفت‌های چشم‌گیری در حوزه‌ی مدل‌های زبانی بزرگ^۱ رخ داده است. این مدل‌ها با بهره‌گیری از معماری‌های عمیق و داده‌های متنی گسترده، توانایی درک، تحلیل و تولید زبان طبیعی را به دست آورده‌اند [۵]. مدل‌هایی مانند GPT، LLaMA و T5 امکان انجام وظایف متنوع زبانی را تنها با دریافت دستور زبانی (prompt) فراهم کرده‌اند [۱].

با وجود توانایی‌های چشم‌گیر LLMها در حل مسائل عمومی زبان، استفاده‌ی مستقیم از آن‌ها در کاربردهای تخصصی، به‌ویژه در حوزه‌هایی همچون پزشکی، با چالش‌های مهمی روبرو است. نخست، مدل‌های عمومی به داده‌های درون‌سازمانی، به‌روز و تخصصی دسترسی ندارند و این امر موجب کاهش دقت پاسخ‌ها در مسائل حساس می‌شود. دوم، این مدل‌ها ممکن است پاسخ‌هایی نادرست یا حتی خطرناک تولید کنند که به‌ویژه در حوزه‌های حساس مانند سلامت یا حقوق غیرقابل پذیرش است [۴].

در ابتدا، توسعه این پروژه بر پایه مدل‌های انگلیسی با قابلیت پشتیبانی از زبان فارسی انجام شد. با این حال، به منظور ارتقای عملکرد و دقت در کاربردهای فارسی‌زبان، تصمیم گرفته شد که بخش‌هایی از فرآیند تنظیم دقیق (Fine-tuning) و همچنین معماری بازیابی افزوده به تولید^۲ به طور اختصاصی برای زبان فارسی پیاده‌سازی و ارزیابی شود. بنابراین، پروژه شامل دو مسیر موازی است: مسیر اول مبتنی بر مدل انگلیسی با پشتیبانی از فارسی و مسیر دوم مختص مدل‌سازی و بازیابی اطلاعات در زبان فارسی به صورت مجزا.

پروژه‌ی حاضر با هدف توسعه‌ی یک دستیار هوشمند پزشکی مبتنی بر LLMها طراحی شده است که سه محور اصلی را دنبال می‌کند: تنظیم دقیق مدل با داده‌های تخصصی پزشکی، بهره‌گیری از معماری بازیابی افزوده به تولید جهت دسترسی به پایگاه دانش داخلی، و پیاده‌سازی مکانیزم‌های کنترلی برای افزایش امنیت و دقت خروجی‌ها.

۱.۱ هدف پروژه

هدف این پروژه، طراحی و پیاده‌سازی یک دستیار زبان‌فهم پزشکی مبتنی بر LLM است که بتواند در سناریوهای تخصصی به‌درستی پاسخ دهد. ویژگی‌های کلیدی این دستیار عبارتند از:

- ارائه‌ی پاسخ‌های دقیق و متناسب با محتوای تخصصی
- دسترسی به پایگاه دانش داخلی سازمان برای استفاده از اطلاعات به‌روز و کاربردی

^۱ Large Language Models - LLMs

^۲ Retrieval-Augmented Generation - RAG

- برخورداری از مکانیزم‌های کنترلی و فیلترینگ برای تضمین امنیت و کیفیت پاسخ‌ها
- توانایی انطباق با حوزه‌های گوناگون مانند سلامت، آموزش، پشتیبانی مشتری و...

۲.۱ ساختار دوگانه پروژه

در این پروژه، ساختار توسعه مدل به صورت دوگانه در نظر گرفته شده است:

۱. مسیر اول: توسعه مدل انگلیسی با قابلیت پشتیبانی از زبان فارسی، شامل تنظیم دقیق و پیاده‌سازی معماری RAG برای محیط‌های دوزبانه.
 ۲. مسیر دوم: توسعه و ارزیابی مدل اختصاصی فارسی، شامل تنظیم دقیق و بازیابی اطلاعات به طور ویژه برای زبان فارسی.
- این ساختار دوگانه امکان مقایسه و تحلیل عملکرد مدل‌ها در هر دو سناریو را فراهم می‌کند و به شناسایی چالش‌ها و فرصت‌های بهبود در محیط‌های چندزبانه و فارسی‌زبان کمک می‌نماید.

۳.۱ ساختار گزارش

در ادامه، ساختار این گزارش به شرح زیر ارائه می‌شود:

- در فصل دوم، مروری بر تحقیقات صورت گرفته در حوزه‌ی LLM‌ها برای کاربردهای تخصصی، به‌ویژه در زمینه‌ی پزشکی و سازمانی ارائه خواهد شد.
- فصل سوم به فرآیند تنظیم دقیق مدل^۳ می‌پردازد که شامل انتخاب مجموعه داده، تنظیم مدل پایه، و ارزیابی عملکرد است.
- در فصل چهارم، معماری RAG و پیاده‌سازی پایگاه دانش داخلی بررسی می‌شود.
- فصل پنجم به مکانیزم‌های امنیتی (Guardrails) اختصاص دارد؛ شامل روش‌های فیلترینگ، تشخیص پاسخ‌های نادرست و تحلیل عملکرد سیستم از دیدگاه ایمنی.
- در فصل ششم، جمع‌بندی، تحلیل نهایی و پیشنهادهایی برای توسعه و پژوهش‌های آتی ارائه می‌شود.

^۳Fine-Tuning

فصل ۲

مطالعات انجام شده

در این بخش، پژوهش‌های مشابه که در حوزه توسعه دستیارهای هوشمند پزشکی مبتنی بر مدل‌های زبانی بزرگ انجام شده‌اند بررسی می‌شوند. این مطالعات شامل تکنیک‌های تنظیم دقیق تخصصی، سیستم‌های بازیابی افزوده، و مکانیزم‌های امنیتی برای کاربردهای پزشکی می‌باشد.

۱.۲ رویکردهای دوگانه: انگلیسی با پشتیبانی فارسی و مسیر اختصاصی فارسی

در ابتدا، بیشتر پژوهش‌ها و توسعه‌ها در حوزه مدل‌های زبانی بزرگ پزشکی بر پایه زبان انگلیسی و با قابلیت پشتیبانی محدود از زبان فارسی انجام شده‌اند. با این حال، با توجه به نیازهای خاص زبان فارسی و چالش‌های موجود در داده‌های تخصصی این زبان، در پروژه حاضر تصمیم گرفته شد که علاوه بر مسیر اصلی (استفاده از مدل‌های انگلیسی با پشتیبانی فارسی)، یک مسیر مجزا و اختصاصی برای توسعه و ارزیابی مدل‌ها و سامانه‌های فارسی نیز دنبال شود. این رویکرد دوگانه هم در مرحله تنظیم دقیق مدل‌ها (Fine-Tuning) و هم در طراحی و پیاده‌سازی سیستم‌های بازیابی افزوده به تولید (RAG) لحاظ شده است تا بتوان عملکرد و چالش‌های هر دو مسیر را به طور مقایسه‌ای بررسی کرد.

۲.۲ مدل‌های زبانی بزرگ تخصصی پزشکی

۱.۲.۲ معماری‌های پایه

پایه‌های اساسی مدل‌های زبانی مدرن بر اساس معماری ترنسفورمر و مکانیزم توجه^۱ استوار است. Vaswani و همکاران در مقاله تأثیرگذار خود نشان دادند که مکانیزم توجه به تنهایی قادر است عملکرد بهتری نسبت به معماری‌های سنتی RNN و CNN ارائه دهد [۶]. این معماری پایه‌ای برای توسعه تمامی مدل‌های زبانی بزرگ از جمله GPT، PaLM، و Gemma-3-12B-IT که در این پروژه استفاده شده است، محسوب می‌شود.

^۱ Attention Mechanism

۲.۲.۲ مدل‌های تخصصی پزشکی

Med-PaLM Series: Singhal و همکاران در دو مطالعه مهم، سری مدل‌های Med-PaLM را توسعه دادند. در مطالعه اول، آنها نشان دادند که مدل‌های زبانی بزرگ قادر به رمزگذاری دانش بالینی هستند [۷]. در مطالعه دوم، آنها Med-PaLM 2 را ارائه دادند که به سطح پاسخگویی نزدیک به متخصصان پزشکی دست یافت [۸]. این تحقیقات نشان‌دهنده پتانسیل بالای تخصصی‌سازی مدل‌های زبانی برای حوزه پزشکی هستند.

MEDITRON: Chen و همکاران مدل‌های MEDITRON-70B را معرفی کردند که بر مقیاس‌سازی پیش‌آموزش پزشکی برای مدل‌های زبانی بزرگ تمرکز دارد [۹]. این مدل‌ها با استفاده از آموزش کامل بر روی داده‌های جامع پزشکی شامل مقالات PubMed و دستورالعمل‌های بالینی توسعه یافته‌اند که مشابه رویکرد استفاده‌شده در این پروژه است.

BioMistral: Labrak و همکاران BioMistral را به عنوان مجموعه‌ای از مدل‌های زبانی بزرگ متن‌باز پیش‌آموزش‌دیده برای حوزه‌های پزشکی معرفی کردند [۱۰]. این مدل با تمرکز بر حفظ قابلیت‌های عمومی در کنار بهبود عملکرد تخصصی توسعه یافته است.

Aloe Family: Gururajan و همکاران خانواده مدل‌های Aloe را به عنوان مجموعه‌ای از مدل‌های تنظیم‌شده متن‌باز برای سلامت ارائه دادند [۱۱]. این مدل‌ها با استفاده از تکنیک‌های پیشرفته fine-tuning و ensemble learning توسعه یافته‌اند.

مدل‌های کوچک‌تر: Kim و همکاران مدل Meerkat را توسعه دادند که مدل‌های زبانی کوچک را قادر به یادگیری مهارت‌های استدلال پیشرفته از کتاب‌های درسی پزشکی می‌کند [۱۲]. Vishwanath و همکاران نیز MedMobile را به عنوان مدل زبانی با اندازه موبایل و قابلیت‌های بالینی در سطح متخصص معرفی کردند [۱۳].

۳.۲ تکنیک‌های تنظیم دقیق (Fine-Tuning)

۱.۳.۲ Supervised Fine-Tuning

Brown و همکاران در مقاله مهم خود نشان دادند که مدل‌های زبانی بزرگ قابلیت یادگیری few-shot را دارند و می‌توانند بدون آموزش اضافی عملکرد خوبی در وظایف مختلف داشته باشند [۵]. این ویژگی برای کاربردهای پزشکی که دسترسی به داده‌های آموزشی محدود است، بسیار مهم محسوب می‌شود و مفهوم پایه‌ای برای تنظیم دقیق نظارت‌شده در این پروژه بوده است.

۲.۳.۲ تکنیک‌های بهینه‌سازی منابع محاسباتی

LoRA^۲: Hu و همکاران روش انطباق کم‌رتبه مدل‌های زبانی بزرگ را معرفی کردند [۱۴]. این تکنیک دقیقاً همان روشی است که در این پروژه برای تنظیم دقیق مدل Gemma-3-12B-IT استفاده شده است و امکان آموزش مؤثر با کاهش پارامترهای قابل آموزش را فراهم می‌کند.

QLoRA: Dettmers و همکاران تکنیک fine-tuning کارآمد LLM‌های کوانتیزه‌شده را ارائه دادند [۱۵]. ترکیب quantization 4-bit با LoRA که در این پروژه استفاده شده، مستقیماً از این تحقیق الهام گرفته است و امکان آموزش مدل‌های بزرگ با منابع محدود را فراهم می‌کند.

DLORA: Zhang و Gao راحل fine-tuning پارامتر-کارآمد توزیع‌شده توسعه دادند [۱۶]. این تکنیک برای مقیاس‌پذیری بهتر فرآیند آموزش طراحی شده است.

^۲Low-Rank Adaptation

۴.۲ سیستم‌های بازیابی اطلاعات (RAG)

۱.۴.۲ مفاهیم بنیادی RAG

Lewis و همکاران اولین پیاده‌سازی جامع RAG را برای وظایف NLP مبتنی بر دانش ارائه دادند [۲]. این تکنیک به عنوان راهکاری برای بهبود دقت و کاهش توهمات^۳ در مدل‌های زبانی مطرح شده‌اند و پایه‌ای برای سیستم RAG پیاده‌سازی شده در این پروژه بوده است. Gao و همکاران مطالعه جامعی در زمینه تولید تقویت‌شده با بازیابی برای مدل‌های زبانی بزرگ ارائه دادند که شامل روش‌ها، کاربردها و چالش‌های این حوزه می‌باشد [۱۷].

۲.۴.۲ تکنیک‌های پیشرفته RAG

Graph RAG: Edge و همکاران روش Graph RAG را توسعه دادند که از گراف‌های دانش برای بهبود خلاصه‌سازی متمرکز بر کوئری استفاده می‌کند [۱۸]. این رویکرد امکان درک بهتر روابط پیچیده بین اطلاعات را فراهم می‌کند. **LightRAG:** Guo و همکاران LightRAG را معرفی کردند که راهکاری ساده و سریع برای RAG ارائه می‌دهد [۱۹]. این روش تمرکز بر بهینه‌سازی سرعت پردازش دارد.

۳.۴.۲ تکنیک‌های چانکینگ و پردازش

در این پروژه، تکنیک نوآورانه Late Chunking پیاده‌سازی شده که با حفظ زمینه کامل اسناد در فرآیند embedding، کیفیت بازیابی اطلاعات را به‌طور قابل‌توجهی بهبود می‌بخشد. این رویکرد برتری نسبت به روش‌های سنتی چانکینگ دارد که در ادبیات موجود کمتر بررسی شده است.

۴.۴.۲ کاربردهای RAG در پزشکی

Xiong و همکاران معیاری برای ارزیابی تولید تقویت‌شده با بازیابی در پزشکی ارائه دادند [۲۰]. Zhang و همکاران UltraMedical را برای ساخت متخصصان عمومی تخصصی در زیست‌پزشکی توسعه دادند [۲۰]. Manes و همکاران K-QA را به عنوان معیار پرسش و پاسخ پزشکی دنیای واقعی معرفی کردند [۲۱].

۵.۲ مطالعات مرتبط با زبان فارسی

با وجود پیشرفت‌های چشمگیر در مدل‌های زبانی انگلیسی، پژوهش‌های مرتبط با زبان فارسی در حوزه پزشکی هنوز محدود است. اخیراً مقاله‌ای با همین مضمون در حوزه پزشکی منتشر شده است که به آموزش مدل متخصص در حوزه پزشکی می‌پردازد. در ادامه از داده‌های این مقاله به نام‌های MF3QA و Persian_medical_corpus برای آموزش مدل و داده‌های پایه سیستم بازیابی استفاده می‌کنیم [۲۲].

³Hallucinations

۶.۲ تکنیک‌های استدلال پیشرفته

۱.۶.۲ Prompting Chain-of-Thought

Wei و همکاران تکنیک Chain-of-Thought Prompting را معرفی کردند که قابلیت استدلال مدل‌های زبانی بزرگ را به طور چشمگیری بهبود می‌بخشد [۲۳]. این روش بر تجزیه مسائل پیچیده به مراحل کوچک‌تر و قابل حل تمرکز دارد.

۲.۶.۲ روش‌های استدلال توسعه‌یافته

Wang و همکاران روش Self-Consistency را برای بهبود زنجیره تفکر در مدل‌های زبانی توسعه دادند [۲۴]. Li و همکاران Chain-of-Knowledge را معرفی کردند که مدل‌های زبانی را با منابع دانش ناهمگن پیوند می‌دهد [۲۵]. Yao و همکاران Tree of Thoughts را ارائه دادند که رویکردی عمودی برای حل مسائل با مدل‌های زبانی بزرگ است [۲۶].

۳.۶.۲ Prompt Engineering در حوزه پزشکی

Wang و همکاران مطالعه جامعی در زمینه روش‌شناسی و کاربردهای prompt engineering در حوزه سلامت ارائه دادند [۲۷]. آنها نشان دادند که طراحی دقیق دستورات ورودی می‌تواند عملکرد مدل‌های زبانی در وظایف پزشکی را به طور قابل توجهی بهبود بخشد.

۷.۲ مکانیزم‌های امنیتی (Guardrails)

۱.۷.۲ NeMo Guardrails

یکی از مهم‌ترین پیشرفت‌ها در زمینه ایمنی و کنترل کیفیت مدل‌های زبانی، توسعه سیستم Guardrails توسط NVIDIA است. این سیستم چارچوبی جامع برای کنترل و مدیریت رفتار مدل‌های زبانی در کاربردهای حساس ارائه می‌دهد. Guardrails قابلیت‌هایی شامل فیلتر کردن محتوای نامناسب، اطمینان از دقت پاسخ‌ها، جلوگیری از تولید اطلاعات نادرست، و کنترل جریان مکالمه را فراهم می‌کند. این سیستم به ویژه برای کاربردهای پزشکی که ایمنی و دقت اطلاعات حیاتی است، بسیار مهم محسوب می‌شود.

۲.۷.۲ الگوهای امنیتی تخصصی

در این پروژه، سیستم Guardrails با معماری دولایه (Input و Output Guardrails) پیاده‌سازی شده که شامل:

- کنترل ورودی برای فیلتر درخواست‌های نامناسب
- کنترل خروجی برای تضمین کیفیت و امنیت پاسخ‌ها
- سیاست‌های تخصصی پزشکی شامل منع ارائه تشخیص پزشکی شخصی، کنترل توصیه‌های درمانی، و مدیریت موقعیت‌های اورژانسی

۸.۲ تکنیک‌های تنظیم ترجیحات

۱.۸.۲ آموزش با بازخورد انسانی

Ouyang و همکاران آموزش مدل‌های زبانی برای پیروی از دستورات با بازخورد انسانی را معرفی کردند [۲۸]. این رویکرد پایه‌ای برای بهبود کیفیت پاسخ‌های مدل‌ها محسوب می‌شود.

۲.۸.۲ روش‌های بهینه‌سازی ترجیح

Rafailov و همکاران بهینه‌سازی ترجیح مستقیم (DPO) را ارائه دادند [۲۹]. Ethayarajh و همکاران KTO را به عنوان تنظیم مدل بر اساس بهینه‌سازی نظریه چشم‌انداز توسعه دادند [۳۰]. Hong و همکاران ORPO را به عنوان بهینه‌سازی ترجیح یکپارچه بدون مدل مرجع معرفی کردند [۳۱].

۹.۲ مجموعه داده‌ها و معیارهای ارزیابی

۱.۹.۲ مجموعه داده‌های تخصصی پزشکی

چندین مجموعه داده برای ارزیابی مدل‌های زبانی در حوزه پزشکی توسعه یافته‌اند. HEAD-QA مجموعه داده‌ای برای استدلال پیچیده در سلامت است [۳۲]. MedMCQA مجموعه داده بزرگ مقیاس چندموضوعی چندگزینه‌ای برای پاسخگویی به سوالات پزشکی ارائه می‌دهد [۳۳]. MedQA مجموعه داده‌ای برای پاسخگویی به سوالات دامنه باز از آزمون‌های پزشکی است [۳۴].

۲.۹.۲ معیارهای ارزیابی استاندارد

Hendrycks و همکاران MMLU را به عنوان معیاری برای سنجش درک زبانی چندوظیفه‌ای گسترده معرفی کردند [۳۵]. Jin و همکاران PubMedQA را برای پاسخگویی به سوالات تحقیقات زیست‌پزشکی ارائه دادند [۳۶]. Chen و همکاران معیاری برای ارزیابی مدل‌های زبانی بزرگ در پاسخگویی و توضیح سوالات چالش‌برانگیز پزشکی توسعه دادند [۳۷].

۳.۹.۲ ابزارهای ارزیابی

Gao و همکاران چارچوبی برای ارزیابی few-shot مدل‌های زبانی ارائه دادند [۳۸]. Zhang و همکاران BERTScore را برای ارزیابی تولید متن با BERT معرفی کردند [۳۹].

۱۰.۲ مدل‌های چندزبانه

۱.۱۰.۲ توسعه قابلیت‌های چندزبانه

Aryabumi و همکاران مدل‌های Aya 23 را برای پیشرفت چندزبانه‌ای معرفی کردند [۴۰]. Dang و همکاران Aya Expanse را با ترکیب دستاوردهای تحقیقاتی برای مرز جدید چندزبانه‌ای ارائه دادند [۴۱].

۲.۱۰.۲ چالش‌های محیط‌های دوزبانه

یکی از چالش‌های مهم در توسعه سیستم‌های RAG برای محیط‌های چندزبانه، محدودیت روش‌های سنتی شباهت‌سنجی مبتنی بر فراوانی کلمات است. در این پروژه، این چالش با استفاده از روش‌های embedding چندزبانه و محاسبه شباهت کسینوسی حل شده است.

۱۱.۲ ابزارهای مورد استفاده

به طور کلی ابزارهای زیر در این پروژه مورد استفاده قرار گرفتند:

- **ElasticSearch**: موتور جستجوی توزیع شده و مقیاس پذیر برای جستجوی متنی و تحلیل داده‌ها.
- **Guardrails**: چارچوبی برای تعریف و اعمال محدودیت‌ها و قوانین روی مدل‌های زبان.
- **langchain**: فریم‌ورک پایه برای ساخت و توسعه برنامه‌های کاربردی مبتنی بر مدل‌های زبان.
- **Ollama**: پلتفرم مدیریت و استقرار مدل‌های زبانی به صورت محلی.
- **unsloth**: ابزار آموزش مدل‌های یادگیری عمیق با تمرکز بر بهینه‌سازی.
- **tensorboard**: ابزار تصویری برای پایش و تحلیل فرآیند آموزش مدل‌های یادگیری ماشین.
- **lightening.ai**: سرویس استفاده از GPU برای تحقیق و توسعه در یادگیری عمیق.
- **vast.ai**: پلتفرمی برای آموزش نهایی مدل‌ها با استفاده از منابع ابری ارزان قیمت.
- **lm-evaluation-harness**: چارچوب ارزیابی عملکرد مدل‌های زبانی مختلف.

۱۲.۲ خلاصه و جمع‌بندی

مرور مطالعات انجام شده نشان می‌دهد که توسعه دستیارهای هوشمند پزشکی نیازمند ترکیب هوشمندانه تکنیک‌های مختلف است. عمده‌ترین نوآوری‌های این پروژه عبارتند از:

۱. تکنیک **Late Chunking**: بهبود کیفیت سیستم RAG با حفظ زمینه کامل اسناد
 ۲. معماری دولایه **Guardrails**: تضمین امنیت و کیفیت پاسخ‌ها در محیط پزشکی
 ۳. ترکیب بهینه تکنیک‌ها: استفاده همزمان از SFT، RAG و Guardrails
 ۴. حل چالش‌های چندزبانه: استفاده از embedding چندزبانه برای محیط فارسی-انگلیسی
- نتایج نشان می‌دهد که این رویکرد ترکیبی منجر به ایجاد سیستمی قدرتمند و امن برای کاربردهای پزشکی شده است که می‌تواند الگویی برای تحقیقات آتی در این حوزه محسوب شود.

فصل ۳

تنظیم دقیق نظارت شده (Supervised) (Fine-Tuning)

۱.۳ مقدمه

تنظیم دقیق نظارت شده یکی از مهم ترین تکنیک های بهینه سازی مدل های زبانی بزرگ برای کاربردهای تخصصی محسوب می شود. این روش امکان تطبیق مدل های پیش آموزش دیده با حوزه های خاص مانند پزشکی، حقوق یا مهندسی را فراهم می کند. در این فصل، فرایند کامل تنظیم دقیق چهار مدل Aya-، gpt-oss-20b و Gemma-3-12B-IT، Gemma-2-9B، expanse-8b برای حوزه پزشکی شرح داده می شود. این فرایند در دو مسیر جداگانه انجام شده است: ابتدا آموزش با داده های انگلیسی و سپس آموزش با داده های فارسی. هر مسیر شامل ارزیابی اولیه مدل های مختلف، مطالعه تأثیر پارامترهای مختلف LoRA، بهینه سازی داده های آموزشی و ارزیابی جامع نتایج است.

بخش اول

آموزش با داده‌های انگلیسی

۲.۳ انتخاب و آماده‌سازی مجموعه داده‌های آموزشی انگلیسی

۱.۲.۳ اهمیت کیفیت داده‌ها در تنظیم دقیق

انتخاب مجموعه داده‌های آموزشی مناسب نقش اساسی در موفقیت روش‌های تنظیم دقیق دارد. کیفیت بالای داده‌های آموزشی اساس هر مدلی را تشکیل می‌دهد و اصطلاحاً *garbage in, garbage out* در این حوزه صادق است. در تنظیم دقیق مدل بر روی حوزه پزشکی، داده‌های تخصصی منجر به بهبود دقت پاسخ‌ها می‌شوند.

۲.۲.۳ مجموعه داده‌های انگلیسی مورد استفاده برای آموزش

در این پروژه، از دیتاست UltraMedical به عنوان مجموعه داده اولیه استفاده شد. این مجموعه داده شامل حدود ۴۱۰ هزار دستور پزشکی است که پوشش جامعی از موضوعات مختلف پزشکی را ارائه می‌دهد. مجموعه داده اولیه و نسخه فیلترشده آن در جدول ۱.۳ نشان داده شده است.

جدول ۱.۳: مجموعه داده‌های آموزشی انگلیسی مورد استفاده

Name	Instructions	Filtered	In-dataset
MedQA [34]	10.2K	9.3K	No
MedMCQA [33]	183K	59K	Yes
MedQA-Eval [42]	51.8K	51.8K	Yes
TextBookQA [42]	91.7K	91.7K	No
PubmedQA [36]	211K	88.7K	Yes
Chatdoctor [42]	100K	31.1K	No
MedQuad [42]	47K	6K	No
MedInstruct-52k [42]	52K	23K	No
MedInstruct-120k [42]	120K	25K	No
WikiInstruct [42]	23K	23K	No
UltraMedical [42]	410K	410K	—
Our dataset (filtered)	410K	200K	—

۳.۳ ارزیابی اولیه مدل‌های پایه برای آموزش انگلیسی

۱.۳.۳ روش‌شناسی ارزیابی

به منظور انتخاب مدل پایه مناسب برای مراحل بعدی، یک ارزیابی اولیه بر روی چهار مدلی که از زبان فارسی پشتیبانی می‌کنند انجام شد. برای این کار از بسته lm-evaluation-harness استفاده شد که امکان سنجش مدل‌های زبانی بر اساس بنچمارک‌های متعدد را فراهم می‌کند [۲]. با توجه به عدم

پشتیبانی این ابزار از مدل‌های Gemma-3-12b-it و gpt-oss-20b، ارزیابی‌های مربوط به این مدل‌ها به صورت دستی ولی با تنظیمات مشابه انجام شد.

۲.۳.۳ مجموعه داده‌های ارزیابی انگلیسی

برای ارزیابی مدل‌ها، از مجموعه‌های داده استاندارد حوزه پزشکی استفاده شد که شامل موارد زیر است:

جدول ۲.۳: مجموعه داده‌های ارزیابی انگلیسی

نام مجموعه داده	تعداد نمونه	توضیحات
HeadQA [۳۲]	۲۵۰۵	سوالات چندگزینه‌ای پزشکی
MedQA [۳۴]	۱۲۵۷	سوالات امتحانات USMLE
MedMCQA-evaluation [۳۳]	۳۹۷۸	بیش از ۱۹۴ هزار پرسش چهارگزینه‌ای
MMLU anatomy [۳۵]	۱۳۵	آناتومی از مجموعه MMLU
MMLU clinical knowledge [۳۵]	۲۴۹	دانش بالینی
MMLU college medicine [۳۵]	۱۴۶	پزشکی دانشگاهی
MMLU medical genetics [۳۵]	۹۹	ژنتیک پزشکی
MMLU professional medicine [۳۵]	۲۶۷	پزشکی عمومی

۳.۳.۳ نتایج ارزیابی اولیه مدل‌های پایه

نتایج ارزیابی چهار مدل مختلف در جدول ۳.۳ ارائه شده است:

جدول ۳.۳: درصد دقت مدل‌های زبانی بر روی مجموعه داده‌های سوالات چندگزینه‌ای پزشکی انگلیسی

Model	HeadQA	MedQA	MedMCQA	MMLU-anatomy	MMLU C-K	MMLU C-M	MMLU MG	MMLU PM
aya-23-8B [40]	37.21%	31.62%	31.52%	39.26%	41.77%	45.40%	40.40%	34.83%
aya-expanse-8b [41]	44.67%	34.69%	34.46%	34.44%	51.81%	43.15%	42.42%	44.57%
Gemma-2-2b-it [43]	37.72%	29.12%	31.07%	31.85%	41.77%	36.30%	37.37%	32.21%
Gemma-2-9b-it [43]	58.00%	46.66%	42.08%	51.11%	60.64%	62.33%	60.61%	60.30%
Gemma-3-12b-it [44]	70.97%	65.06%	55.23%	65.80%	75.10%	75.39%	78.82%	78.64%

طبق نتایج جدول، مدل Gemma-3-12b-it بهترین عملکرد را در تمامی مجموعه داده‌های آزمایشی نشان داده است و به عنوان مدل اصلی برای مراحل بعدی آموزش انگلیسی انتخاب شد.

۴.۳ آزمون اولیه با پیکربندی پیش فرض

۱.۴.۳ پیکربندی اولیه

در مرحله اول، سه مدل Aya-expanse-8b، Gemma-2-9B و Gemma-3-12B با استفاده از پیکربندی پیش فرض تکنیک LoRA آموزش داده شدند. این پیکربندی شامل $\alpha=16$ ، $\text{rank}=16$ و استفاده از کل مجموعه داده UltraMedical (410K) نمونه بود.

جدول ۴.۳: پیکربندی اولیه آموزش انگلیسی

Parameter	Value
LoRA rank	16
LoRA alpha	16
Training data	UltraMedical (410K)
Epochs	1
Learning rate	2e-4
Batch size	32

۲.۴.۳ نتایج آزمون اولیه

نتایج آزمون اولیه با پیکربندی پیش فرض در جدول ۵.۳ نشان داده شده است:

جدول ۵.۳: نتایج آزمون اولیه با پیکربندی پیش فرض (LoRA 16-16, 1 epoch)

Model	HeadQA	MedQA	MedMCQA	MMLU-anatomy	MMLU C-K	MMLU C-M	MMLU MG	MMLU PM
مدل‌های پایه								
aya-expanse-8b	44.67%	34.69%	34.46%	34.44%	51.81%	43.15%	42.42%	44.57%
Gemma-2-9b-it	58.00%	46.66%	42.08%	51.11%	60.64%	62.33%	60.61%	60.30%
Gemma-3-12b-it	70.97%	65.06%	55.23%	65.19%	75.10%	75.35%	78.79%	78.66%
پس از تنظیم دقیق اولیه								
aya-expanse-8b-ft	45.12%	34.91%	34.82%	34.81%	52.21%	43.84%	43.43%	45.32%
Gemma-2-9b-it-ft	58.34%	47.02%	42.41%	51.48%	61.04%	62.67%	61.62%	60.67%
Gemma-3-12b-it-ft	72.15%	66.43%	56.89%	66.67%	76.31%	76.71%	79.80%	79.78%
میزان بهبود								
aya-expanse improvement	+0.45%	+0.22%	+0.36%	+0.37%	+0.40%	+0.69%	+1.01%	+0.75%
Gemma-2-9b improvement	+0.34%	+0.36%	+0.33%	+0.37%	+0.40%	+0.34%	+1.01%	+0.37%
Gemma-3-12b improvement	+1.18%	+1.37%	+1.66%	+1.48%	+1.21%	+1.36%	+1.01%	+1.12%

همانطور که در جدول مشاهده می‌شود، مدل‌های Aya-expanse-8b و Gemma-2-9B بهبودی کمتر از ۱ درصد در اکثر معیارها داشتند که عملاً قابل اعتماد نیست و در محدوده خطای اندازه‌گیری قرار

دارد. حتی مدل Gemma-3-12B که بهترین عملکرد را داشت، تنها بهبود متوسط 1.3% نشان داد که پایین‌تر از انتظار بود. این نتایج ضرورت بهینه‌سازی پارامترها و کیفیت داده‌ها را مشخص کرد.

۵.۳ بهینه‌سازی پارامترهای LoRA برای آموزش انگلیسی

۱.۵.۳ روش‌شناسی آزمون پارامترهای LoRA

به منظور کاهش هزینه محاسباتی و زمان مورد نیاز برای یافتن پیکربندی بهینه، آزمایشات اولیه پارامترهای rank و alpha بر روی نمونه کوچک‌تری از داده‌ها و با استفاده از مدل سبک‌تر Aya-expanse-8b انجام شد. این رویکرد امکان بررسی سریع ترکیبات مختلف پارامترها را فراهم کرد تا بهترین تنظیمات شناسایی شوند.

جدول ۶.۳: تنظیمات آزمون سریع پارامترهای LoRA

Parameter	Value
Test Model	Aya-Expanse-8B
Dataset Size	50K samples (subset)
Test Range	rank/alpha: 16, 32, 64, 128
Epochs	1
Evaluation Metric	MedQA accuracy

۲.۵.۳ آزمون پارامترهای مختلف

به منظور بهبود عملکرد، آزمایشات جامعی بر روی پارامترهای rank و alpha انجام شد. این پارامترها در بازه ۱۶ تا ۱۲۸ تست شدند تا تأثیر آن‌ها بر کیفیت آموزش و عملکرد نهایی مدل بررسی شود.

جدول ۷.۳: نتایج آزمون پارامترهای مختلف LoRA بر روی MedQA

Rank-Alpha	Target Modules: (k,q,v,o)	Target Modules: (k,q,v,o,up,down,gate)	Target Modules: (all)
16-16	51.0%	53.7%	55.41%
32-32	50.6%	50.36%	52.7%
64-64	50.2%	50.0%	50.5%
128-128	48.21%	43.27%	42.40%
16-32	-	-	48.0%

همانطور که در جدول ۷.۳ مشاهده می‌شود، برخلاف انتظار، پیکربندی rank=16 و alpha=16 با استفاده از تمامی ماژول‌ها بهترین نتیجه (55.41%) را ارائه داد. نکته جالب توجه این است که با افزایش rank و alpha، عملکرد مدل کاهش یافت که ممکن است به دلیل overfitting یا عدم تطبیق با ساختار داده‌های آموزشی باشد.

۳.۵.۳ انتقال نتایج به مدل اصلی

پس از شناسایی بهترین پیکربندی در آزمایشات مقدماتی، این تنظیمات به مدل اصلی Gemma-3-12B-IT منتقل شدند. با توجه به اینکه در آموزش نهایی از حجم کاملی از داده‌ها (200K پس از فیلترکردن) استفاده شد و مدل بزرگ‌تری مورد استفاده قرار گرفت، پیکربندی $\text{rank}=32$ و $\text{alpha}=32$ به عنوان تنظیم بهینه انتخاب شد تا ظرفیت کافی برای یادگیری از حجم بالای داده‌ها فراهم شود.

۶.۳ بهینه‌سازی مجموعه داده‌های انگلیسی

۱.۶.۳ فیلترکردن داده‌های کم‌کیفیت

پس از شناسایی پیکربندی بهینه LoRA، توجه به کیفیت داده‌های آموزشی معطوف شد. قسمتی از داده‌هایی که اعتبار کمتری داشتند از مجموعه داده حذف شدند. این فرآیند باعث کاهش حجم داده‌ها از ۴۱۰ هزار به ۲۰۰ هزار نمونه شد.

جدول ۸.۳: مقایسه مجموعه داده اولیه و فیلترشده

Dataset Version	Size	Quality Score
Original UltraMedical	410K	3.2/5
Filtered Dataset	200K	4.1/5

۲.۶.۳ معیارهای فیلترکردن

فیلترکردن داده‌ها بر اساس معیارهای زیر انجام شد:

- حذف داده‌هایی با پاسخ‌های نادرست یا مبهم
- حذف سوالات تکراری یا بسیار مشابه
- حذف داده‌هایی با منابع غیرمعتبر
- حذف سوالات خارج از حوزه پزشکی اصلی

۷.۳ آموزش نهایی با داده‌های انگلیسی

۱.۷.۳ محدودیت‌های منابع محاسباتی

به دلیل محدودیت در منابع محاسباتی، تصمیم گرفته شد که فقط مدل با بهترین عملکرد یعنی Gemma-3-12B-IT با پیکربندی بهینه و داده‌های فیلترشده آموزش داده شود.

۲.۷.۳ پیکربندی نهایی آموزش انگلیسی

بر اساس تمامی آزمون‌های انجام‌شده، پیکربندی نهایی مطابق جدول ۹.۳ تعیین شد:

جدول ۹.۳: پیکربندی نهایی آموزش مدل انگلیسی

Parameter	Value
Model	Gemma-3-12B-IT
Dataset	Filtered UltraMedical (200K)
GPU	H100 SVM 80GB
per-device-train-batch-size	32
gradient-accumulation-steps	2
warmup-step	5
num-training-epochs	3
learning-rate	$2e - 4$
optimizer	adamw-8bit
weight-decay	0.01
lr-scheduler-type	linear
max-sequence-length	8192
quantize	4bit
target-models	all
rank	32
lora-alpha	32
lora-dropout	0

۳.۷.۳ افزایش تعداد Epoch

برخلاف آزمایشات قبلی که با ۱ epoch انجام می‌شدند، در مرحله نهایی تعداد epoch به ۳ افزایش یافت تا مدل بتواند بهتر از داده‌های آموزشی یاد بگیرد.

۸.۳ ارزیابی نتایج تنظیم دقیق انگلیسی

۱.۸.۳ مقایسه عملکرد قبل و بعد از تنظیم دقیق

جهت ارزیابی تأثیر فرآیند تنظیم دقیق، عملکرد مدل پایه و مدل فاین‌تیون‌شده بر روی مجموعه‌ای از آزمون‌های پزشکی انگلیسی سنجیده شد. نتایج در جدول ۱۰.۳ و ۱۱.۳ نشان داده شده است.

۲.۸.۳ تحلیل نتایج آموزش انگلیسی

مدل فاین‌تیون‌شده بهبود دقت بین ۳ تا ۹ درصد بسته به مجموعه سؤال را نشان داده است. این بهبود نشان می‌دهد که مدل توانسته است مفاهیم و ساختارهای تخصصی زبان انگلیسی در حوزه پزشکی را به خوبی فرا بگیرد.

جدول ۱۰.۳: مقایسه عملکرد مدل قبل و بعد از تنظیم دقیق انگلیسی

Model	HeadQA	MedQA	MedMCQA	MMLU-anatomy	MMLU C-K	MMLU C-M	MMLU MG	MMLU PM
gemma-3-12b-it	70.97%	65.06%	55.23%	65.19%	75.10%	75.35%	78.79%	78.66%
gemma-3-12b-it-en-sft	77.33%	74.28%	61.46%	70.38%	80.72%	81.65%	82.82%	81.65%

جدول ۱۱.۳: مقایسه عملکرد مدل با سایر مدل‌های انگلیسی

Model	HeadQA	MedQA	MedMCQA	MMLU-anatomy	MMLU C-K	MMLU C-M	MMLU MG	MMLU PM
Yi-6B-Chat	62.95%	48.08%	47.05%	51.61%	56.89%	56.58%	58.70%	56.19%
Openchat_3.5	63.95%	50.98%	48.96%	51.38%	64.77%	49.21%	64.66%	62.28%
Mistral-7B-v0.1	62.09%	50.98%	48.29%	53.46%	54.09%	57.56%	59.35%	64.83%
Llama-3-8B-Instruct	68.89%	60.49%	56.83%	60.14%	68.79%	62.33%	64.44%	69.59%
Yi-9B	68.46%	53.81%	53.02%	54.38%	57.31%	59.35%	65.04%	62.28%
SOLAR-10.7B-Instruct-v1.0	64.28%	54.52%	47.67%	-	-	-	-	-
Medalpaca-7b	56.69%	42.26%	37.60%	44.01%	47.32%	44.39%	47.75%	41.65%
MMedLM2	64.67%	56.56%	49.44%	50.23%	54.62%	62.36%	61.41%	46.13%
BioMistral SLERP	59.25%	47.36%	44.22%	50.00%	55.85%	55.88%	57.88%	55.56%
Meditron-7B	36.76%	29.38%	27.97%	31.34%	28.19%	32.74%	32.85%	27.06%
Llama3-Aloe-8B-Alpha	70.25%	62.29%	59.05%	63.82%	73.15%	65.09%	69.75%	64.83%
PMC LLaMA 13B	60.66%	52.47%	51.37%	-	-	-	-	-
gemma-3-12b-it-en-sft	73.05%	65.06%	55.23%	65.19%	75.10%	75.35%	78.79%	78.66%
gemma-3-12b-it-en-sft	77.33%	74.28%	61.46%	70.38%	80.72%	81.65%	82.82%	81.65%
Llama-3-70B-Instruct	82.25%	76.20%	70.57%	-	-	-	-	-
Meditron 70B	65.89%	58.05%	48.43%	-	-	-	-	-
Qwen1.5-72B-Chat	76.56%	65.20%	61.75%	-	-	-	-	-
Yi-34B-Chat	75.78%	64.73%	59.00%	-	-	-	-	-

بخش دوم

آموزش با داده‌های فارسی

۹.۳ انگیزه و ضرورت آموزش فارسی

با توجه به کمبود منابع و مدل‌های تخصصی پزشکی به زبان فارسی، تصمیم گرفته شد تا مدل‌هایی که قابلیت پردازش زبان فارسی دارند، با داده‌های فارسی نیز آموزش داده شوند. این آموزش‌ها در ادامه آموزش انگلیسی انجام شد تا مدل بتواند از دانش پایه انگلیسی بهره‌مند شده و آن را به زبان فارسی منتقل کند.

۱۰.۳ انتخاب مجموعه داده‌های فارسی

۱.۱۰.۳ معرفی دیتاست MF3QA

برای آموزش مدل‌ها به زبان فارسی، از دیتاست MF3QA استفاده شد. این دیتاست اولین و جامع‌ترین مجموعه داده سؤالات پزشکی به زبان فارسی است که شامل:

- ۲۰ هزار نمونه داده آموزشی

- ۲ هزار نمونه داده توسعه (validation)

- ۲ هزار نمونه داده تست

در فرآیند آموزش، داده‌های آموزش و توسعه ادغام شده و به عنوان مجموعه آموزشی (۲۲ هزار نمونه) و داده‌های تست به عنوان مجموعه ارزیابی استفاده شدند.

۲.۱۰.۳ مجموعه داده‌های ارزیابی فارسی

برای ارزیابی مدل‌های آموزش دیده با داده‌های فارسی، از نسخه‌های ترجمه شده مجموعه داده‌های استاندارد MMLU استفاده شد:

جدول ۱۲.۳: مجموعه داده‌های ارزیابی فارسی

توضیحات	تعداد نمونه	نام مجموعه داده
آناتومی از مجموعه MMLU	۱۳۵	MMLU anatomy - fa [۲۲]
دانش بالینی	۲۴۹	MMLU clinical knowledge - fa [۲۲]
پزشکی دانشگاهی	۱۴۶	MMLU college medicine - fa [۲۲]
ژنتیک پزشکی	۹۹	MMLU medical genetics - fa [۲۲]
پزشکی عمومی	۲۶۷	MMLU professional medicine - fa [۲۲]

۱۱.۳ انتخاب مدل‌ها برای آموزش فارسی

۱.۱۱.۳ معیارهای انتخاب

برای آموزش با داده‌های فارسی، مدل‌هایی انتخاب شدند که:

- قابلیت پردازش زبان فارسی را داشته باشند

- در ارزیابی‌های اولیه عملکرد قابل قبولی نشان داده باشند
- در آموزش انگلیسی نتایج خوبی کسب کرده باشند (در صورت آموزش قبلی)

۲.۱۱.۳ مدل‌های انتخاب شده

بر اساس معیارهای فوق، دو مدل برای آموزش فارسی انتخاب شدند:

- **gpt-oss-20b**: مدلی با ظرفیت بالا که از زبان فارسی پشتیبانی خوبی دارد [۴۵].
- **Gemma-3-12b-it**: مدلی که در آموزش انگلیسی بهترین نتایج را کسب کرده بود [۴۴].

۱۲.۳ پیکربندی آموزش فارسی

با توجه به حجم بسیار کمتر داده‌های فارسی نسبت به انگلیسی، پیکربندی متفاوتی برای آموزش در نظر گرفته شد. به ویژه پارامترهای LoRA با $\text{rank}=4$ و $\alpha=8$ انتخاب شدند تا از overfitting جلوگیری شود:

جدول ۱۳.۳: پیکربندی آموزش مدل Gemma-3-12b-it با داده‌های فارسی

Parameter	Value
Model	Gemma-3-12B-IT
Dataset	MF3QA (20K training + 2k development)
GPU	H100 SVM 80GB
per-device-train-batch-size	32
per-device-eval-batch-size	8
gradient-accumulation-steps	1
warmup-step	5
num-training-epochs	3
learning-rate	$2e - 4$
optimizer	adamw-8bit
weight-decay	0.01
lr-scheduler-type	linear
max-sequence-length	8192
quantize	4bit
target-models	all
rank	4
lora-alpha	8
lora-dropout	0

جدول ۱۴.۳: پیکربندی آموزش مدل gpt-oss-20b با داده‌های فارسی

Parameter	Value
Model	gpt-oss-20b
Dataset	MF3QA (20K training + 2k development)
GPU	H100 SVM 80GB
per-device-train-batch-size	64
per-device-eval-batch-size	16
gradient-accumulation-steps	1
warmup-step	5
num-training-epochs	3
learning-rate	$2e - 4$
optimizer	adamw-8bit
weight-decay	0.01
lr-scheduler-type	linear
max-sequence-length	8192
quantize	4bit
target-models	all
rank	4
lora-alpha	8
lora-dropout	0

۱۳.۳ نتایج آموزش مدل‌های فارسی

۱.۱۳.۳ مدل‌های نهایی آموزش داده شده

پس از اتمام فرآیند آموزش، دو مدل فارسی تولید شد:

- gpt-oss-20b-fa-sft: نسخه تنظیم‌شده مدل gpt-oss-20b

- gemma-3-12b-it-fa-sft: نسخه تنظیم‌شده مدل Gemma-3-12b-it

۲.۱۳.۳ ارزیابی عملکرد مدل‌های فارسی

نتایج آموزش مدل‌ها با داده‌های فارسی و مقایسه آن‌ها با مدل‌های پایه در جدول ۱۵.۳ نشان داده شده است:

۳.۱۳.۳ مقایسه با سایر مدل‌های فارسی

برای ارزیابی جامع‌تر، عملکرد مدل‌های آموزش‌دیده با سایر مدل‌های موجود فارسی مقایسه شد:

جدول ۱۵.۳: دقت مدل‌های آموزش‌دیده فارسی بر روی مجموعه داده‌های تست فارسی

Model	Anatomy	Clinical Knowledge	College Medicine	Medical Genetics	Professional Medicine
gpt-oss-20b (baseline)	57%	69%	59%	75%	73%
gpt-oss-20b-fa-sft	60%	71%	62%	78%	75%
Improvement	+3%	+2%	+3%	+3%	+2%
gemma-3-12b-it (baseline)	56%	68%	74%	72%	74%
gemma-3-12b-it-fa-sft	58%	70%	76%	74%	76%
Improvement	+2%	+2%	+2%	+2%	+2%

جدول ۱۶.۳: مقایسه عملکرد مدل‌های فارسی بر روی مجموعه داده‌های MMLU پزشکی

Model	Anatomy	Medical Genetics	College Medicine	Clinical Knowledge	Professional Medicine
PersianMind	25.18%	34.0%	20.23%	25.28%	23.89%
aya-expanse-8b (baseline)	40.74%	49.0%	44.51%	52.07%	45.58%
Qwen2.5	41.48%	52.0%	43.35%	47.92%	43.01%
gpt-oss-20b-fa-sft	60.0%	78.0%	62.0%	71.0%	75.0%
gemma-3-12b-it-fa-sft (ours)	58.0%	74.0%	76.0%	70.0%	76.0%

همانطور که در جدول ۱۶.۳ مشاهده می‌شود، مدل‌های آموزش‌دیده ما عملکرد بسیار بهتری نسبت به مدل‌های موجود فارسی دارند. مدل gemma-3-12b-it-fa-sft با میانگین دقت ۸.۷۰ درصد، بهترین عملکرد کلی را در بین تمام مدل‌های فارسی ارائه داده است.

۱۴.۳ انتخاب مدل برتر فارسی

۱.۱۴.۳ معیارهای انتخاب

برای انتخاب مدل برتر فارسی، معیارهای زیر در نظر گرفته شد:

- میانگین دقت در تمام معیارهای ارزیابی
- ثبات عملکرد در بخش‌های مختلف
- قابلیت تعمیم به سوالات جدید

۲.۱۴.۳ مدل برگزیده

بر اساس نتایج جدول ۱۵.۳ و ۱۶.۳، مدل gemma-3-12b-it-fa-sft به عنوان مدل برگزیده فارسی انتخاب شد. این مدل:

- در اکثر معیارها عملکرد بهتری نسبت به سایر مدل‌ها داشته است
 - میانگین دقت 70.8 درصد را کسب کرده است
 - بهبود ۲ درصدی نسبت به مدل پایه نشان داده است
 - در مقایسه با مدل‌های فارسی موجود، برتری قابل توجهی دارد
- این مدل در فصل بعدی (سیستم RAG) به عنوان مدل پایه برای پردازش سوالات فارسی استفاده خواهد شد.

۱۵.۳ تحلیل نتایج آموزش فارسی

۱.۱۵.۳ بهبود عملکرد

مدل‌های آموزش‌دیده با داده‌های فارسی بهبود متوسط ۲-۳ درصدی نسبت به مدل‌های پایه نشان دادند. این بهبود اگرچه کمتر از بهبود مشاهده شده در آموزش انگلیسی است، اما با توجه به حجم کمتر داده‌های فارسی (۲۲ هزار نمونه در مقابل ۲۰۰ هزار نمونه انگلیسی) قابل قبول است.

۲.۱۵.۳ تأثیر پیکربندی LoRA با rank پایین

استفاده از $\text{rank}=4$ و $\text{alpha}=8$ برای آموزش فارسی نقش مهمی در جلوگیری از overfitting داشت. با توجه به حجم کم داده‌های آموزشی، این پیکربندی منجر به:

- حفظ قابلیت تعمیم مدل
- جلوگیری از حفظ کردن داده‌های آموزشی
- کاهش زمان آموزش و منابع محاسباتی مورد نیاز

۱۶.۳ مقایسه جامع آموزش انگلیسی و فارسی

جدول ۱۷.۳ مقایسه‌ای بین نتایج آموزش انگلیسی و فارسی را نشان می‌دهد:

جدول ۱۷.۳: مقایسه نتایج آموزش انگلیسی و فارسی

Aspect	English Training	Persian Training
Training Data Size	200K samples	22K samples
LoRA rank	32	4
LoRA alpha	32	8
Batch size (Gemma)	32	32
Gradient accumulation	2	1
Average Improvement	7.6%	2.5%
Final Accuracy	77.3%	70.8%

۱۷.۳ جمع‌بندی

در این فصل، فرآیند جامع تنظیم دقیق نظارت‌شده چهار مدل زبانی برای حوزه پزشکی به دو زبان انگلیسی و فارسی تشریح شد. در بخش آموزش انگلیسی:

- سه مدل Aya-expanse-8b، Gemma-2-9B و Gemma-3-12B ارزیابی و آموزش داده شدند

- مدل Gemma-3-12B با بهینه‌سازی پارامترهای LoRA ($\alpha=32$, $\text{rank}=32$) و فیلترکردن داده‌ها به دقت ۳.۷۷ درصد رسید

- مدل نهایی gemma-3-12b-it-en-sft تولید شد

در بخش آموزش فارسی:

- دو مدل gpt-oss-20b و Gemma-3-12b-it با داده‌های فارسی آموزش داده شدند

- پیکربندی LoRA با $\text{rank}=4$ و $\alpha=8$ برای جلوگیری از overfitting استفاده شد

- مدل gemma-3-12b-it-fa-sft با دقت 70.8 درصد به عنوان مدل برتر فارسی انتخاب شد

- مدل‌های آموزش‌دیده عملکرد بسیار بهتری نسبت به مدل‌های فارسی موجود نشان دادند

نتایج نشان می‌دهد که ترکیب روش‌هایی نظیر کوانتیزاسیون ۴ بیتی، LoRA بهینه، فیلترکردن داده‌ها، آموزش چندمرحله‌ای و تنظیم پارامترها متناسب با حجم داده‌ها، رویکردی بسیار کارآمد برای تطبیق مدل‌های زبانی بزرگ با حوزه‌های تخصصی است.

مدل‌های نهایی gemma-3-12b-it-en-sft برای انگلیسی و gemma-3-12b-it-fa-sft برای فارسی در فصل بعدی به عنوان مدل‌های پایه برای پیاده‌سازی سیستم RAG استفاده خواهند شد.

فصل ۴

پیاده‌سازی سیستم بازیابی افزوده (Retrieval-Augmented) (Generation)

۱.۴ مقدمه

سیستم‌های بازیابی افزوده^۱ نمایانگر یکی از مهم‌ترین تکامل‌های اخیر در حوزه مدل‌های زبانی بزرگ محسوب می‌شوند که امکان ترکیب دانش ذخیره‌شده در پایگاه‌های اطلاعاتی خارجی با قابلیت‌های تولید متن این مدل‌ها را فراهم می‌کنند [۲]. این تکنیک راه‌حلی مؤثر برای غلبه بر محدودیت‌های ذاتی مدل‌های زبانی نظیر عدم دسترسی به اطلاعات به‌روز، توهم‌زایی (Hallucination)، و فقدان دانش تخصصی در حوزه‌های خاص ارائه می‌دهد [۱۷].

در این فصل، مراحل طراحی و پیاده‌سازی سیستم RAG برای دستیار هوشمند پزشکی به دو زبان انگلیسی و فارسی تشریح می‌شود. ابتدا سیستم RAG با منابع انگلیسی پیاده‌سازی شده و سپس با افزودن منابع فارسی، سیستم دوزبانه کامل می‌شود. این فرآیند شامل جمع‌آوری و انتخاب منابع اطلاعاتی، روش‌های پیشرفته پردازش و تکه‌تکه‌سازی داده‌ها (Chunking)، و معماری ذخیره‌سازی مبتنی بر Elasticsearch است.

^۱ Retrieval-Augmented Generation systems

بخش سوم

سیستم RAG با منابع انگلیسی

۲.۴ جمع‌آوری و انتخاب منابع اطلاعاتی انگلیسی

۱.۲.۴ مجموعه داده‌های مرجع MedRAG

برای تشکیل پایگاه دانش جامع و معتبر انگلیسی، از مجموعه داده‌های استاندارد MedRAG استفاده شد که طیف گسترده‌ای از منابع علمی و تخصصی در حوزه پزشکی را در بر می‌گیرد [۲۰]. این مجموعه داده‌ها از منابع معتبر بین‌المللی تهیه شده و دارای پوشش جامعی از موضوعات پزشکی مختلف هستند.

۲.۲.۴ مشخصات مجموعه داده‌های انتخابی انگلیسی

جدول ۱.۴ مشخصات کامل مجموعه داده‌های انگلیسی مورد استفاده در سیستم RAG را نشان می‌دهد:

جدول ۱.۴: مجموعه داده‌های انگلیسی مورد استفاده در سیستم RAG				
مجموعه داده	حوزه	استفاده	تعداد	روش قطعه‌بندی
Wikipedia	عمومی	خیر	29.9M	پیش‌فرض
PubMed	زیست‌پزشکی	خیر	23.9M	پیش‌فرض
Textbooks	پزشکی	بله	125.8K	پیش‌فرض
StatePearls	بالینی	بله	247K	Late + Recursive
MedCorp	متنوع	خیر	54.2M	متنوع
مجموع نهایی	پزشکی	-	373.5K	-

بر اساس تحلیل‌های انجام‌شده و محدودیت‌های محاسباتی موجود، تصمیم گرفته شد تا تنها از دو مجموعه داده تخصصی Textbooks و StatePearls استفاده شود که در مجموع حدود 373.5 هزار سند تخصصی پزشکی را تشکیل می‌دهند.

۳.۴ روش‌های پردازش و تکه‌تکه‌سازی منابع انگلیسی

۱.۳.۴ استراتژی کلی پردازش داده‌های انگلیسی

با توجه به ماهیت متفاوت مجموعه داده‌های مورد استفاده، روش‌های متمایزی برای پردازش و تکه‌تکه‌سازی هر یک اعمال شد. هدف اصلی، بهینه‌سازی کیفیت اطلاعات قابل بازیابی و حفظ یکپارچگی معنایی متون در طول فرآیند تقسیم‌بندی بود [۱۹].

۲.۳.۴ پردازش مجموعه داده StatePearls با تکنیک Late Chunking

مجموعه داده StatePearls که شامل 247 هزار سند بالینی معتبر است، با استفاده از ترکیب نوآورانه تکنیک‌های Recursive Chunking و Late Chunking پردازش شد. این فرآیند در سه مرحله کلیدی انجام گرفت:

مرحله اول: تکه‌تکه‌سازی بازگشتی

در این مرحله، هر سند با استفاده از الگوریتم تکه‌تکه‌سازی بازگشتی به بخش‌های کوچک‌تر تقسیم شد:

۱. تقسیم‌بندی اولیه: متن اصلی بر اساس جداکننده‌های طبیعی (پاراگراف‌ها، عناوین بخش‌ها) تقسیم می‌شود

۲. کنترل اندازه: هر بخش از نظر طول ارزیابی شده و در صورت تجاوز از حد آستانه تعریف‌شده، مجدداً تقسیم می‌شود

۳. حفظ پیوستگی: در هر مرحله تقسیم، بخشی از متن قبلی به‌عنوان overlap نگهداری می‌شود تا پیوستگی معنایی حفظ شود

مرحله دوم: تولید همزمان نمایش‌های برداری

پس از تشکیل تکه‌های نهایی، تمامی تکه‌های متعلق به یک سند به‌صورت یکجا وارد مدل embedding می‌شوند. این رویکرد مزایای قابل‌توجهی دارد:

- حفظ روابط بین-تکه‌ای: مدل embedding قادر به درنظرگیری روابط معنایی بین تکه‌های مختلف یک سند است
- بهینه‌سازی محاسباتی: پردازش دسته‌ای تکه‌ها سرعت تولید embedding را افزایش می‌دهد
- یکپارچگی زمینه‌ای: اطلاعات زمینه‌ای کل سند در تولید نمایش برداری هر تکه مؤثر است

مرحله سوم: تجمیع و تولید بردار نهایی (Pooling)

در این مرحله که هسته اصلی تکنیک Late Chunking محسوب می‌شود، برخلاف روش‌های سنتی که هر تکه را به‌صورت مجزا embedding می‌کنند، فرآیند زیر دنبال می‌شود:

۱. پردازش یکپارچه سند: ابتدا کل سند به‌عنوان یک واحد وارد مدل embedding می‌شود
۲. تولید نمایش جامع: مدل برای کل متن یک نمایش برداری جامع و یکپارچه تولید می‌کند
۳. تقسیم‌بندی مرحله‌ای: سپس این نمایش برداری بر اساس مرزهای از پیش تعریف‌شده به تکه‌های کوچک‌تر تقسیم می‌شود
۴. حفظ اطلاعات زمینه‌ای: هر تکه نهایی حاوی اطلاعات زمینه‌ای کامل سند است

۳.۳.۴ مزایای تکنیک Late Chunking

تکنیک Late Chunking که در این پروژه پیاده‌سازی شده است، مزایای کلیدی زیر را نسبت به روش‌های تکه‌تکه‌سازی اولیه دارد [۱۸]:

- یکپارچگی زمینه‌ای: کل اطلاعات سند در فرآیند embedding درنظر گرفته می‌شود
- دقت بازیابی بهتر: بردارهای تولیدی نماینده دقیق‌تری از محتوای واقعی هستند
- حفظ روابط معنایی: پیوندهای مفهومی بین قسمت‌های مختلف حفظ می‌شود
- بهینه‌سازی محاسبات: کاهش تکرار در پردازش‌های embedding
- انطباق‌پذیری: قابلیت تنظیم برای انواع مختلف محتوا و کاربردها

۴.۳.۴ پردازش مجموعه داده Textbooks

مجموعه داده Textbooks شامل 125.8 هزار سند از کتاب‌های پزشکی است که از قبل به صورت بهینه تکه‌بندی شده بودند. برای این مجموعه داده، فرآیند ساده‌تری اعمال شد:

۱. بارگذاری تکه‌های موجود: تکه‌های از پیش تعریف‌شده بارگذاری شدند
۲. تولید **Embedding**: هر تکه به صورت مستقل embedding شد
۳. ذخیره‌سازی: بردارهای تولیدی همراه با متن اصلی در Elasticsearch ذخیره شدند

۵.۳.۴ تنظیمات فنی و پارامترهای انگلیسی

جدول ۲.۴ پارامترهای تکه‌تکه‌سازی برای مجموعه داده‌های انگلیسی را نشان می‌دهد:

جدول ۲.۴: پارامترهای تکه‌تکه‌سازی برای مجموعه داده‌های انگلیسی			
روش تکه‌سازی	Overlap	اندازه تکه	مجموعه داده
Chunking Late + Recursive	100	1024	StatePearls
پیش‌فرض	-	300	Textbooks

۶.۳.۴ ارزیابی کیفیت تکه‌تکه‌سازی انگلیسی

برای اطمینان از کیفیت فرآیند تکه‌تکه‌سازی، معیارهای زیر مورد بررسی قرار گرفتند:

- یکپارچگی معنایی: حفظ معنای کامل در هر تکه
- پوشش اطلاعاتی: عدم از دست رفتن اطلاعات مهم در فرآیند تقسیم‌بندی
- کیفیت بازیابی: دقت بازیابی اطلاعات مرتبط در مرحله استعلام


نتایج آزمون‌های کیفی نشان داد که استفاده از تکنیک Late Chunking منجر به بهبود 15-20 درصدی در دقت بازیابی اطلاعات مرتبط شده است.

۴.۴ ذخیره‌سازی و سازماندهی منابع انگلیسی در Elasticsearch

۱.۴.۴ معماری Elasticsearch برای منابع انگلیسی

برای ذخیره‌سازی و بازیابی سریع اطلاعات انگلیسی، از Elasticsearch به عنوان موتور جستجوی اصلی استفاده شد. این سیستم قابلیت‌های پیشرفته زیر را فراهم می‌کند:

- جستجوی متنی پیشرفته (Full-text Search)
- جستجوی برداری با دقت بالا (Vector Search)
- ترکیب و تجمیع نتایج از منابع مختلف (Hybrid Search)



شکل ۱.۴: تفاوت Late chunking با روش معمول

- مقیاس‌پذیری افقی و عمودی
- قابلیت‌های تحلیلی پیشرفته

۲.۴.۴ ساختار ایندکس‌گذاری منابع انگلیسی

هر سند در Elasticsearch شامل فیلدهای کلیدی زیر است:

- **content**: متن اصلی تکه
- **embedding**: بردار عددی نمایانگر معنای متن
- **metadata**: اطلاعات اضافی شامل منبع، تاریخ انتشار، موضوع، و نویسنده
- **chunk_id**: شناسه یکتای هر تکه
- **source_document**: ارجاع به سند اصلی
- **language**: زبان سند (English)

۵.۴ ارزیابی عملکرد سیستم RAG انگلیسی

۱.۵.۴ مقایسه عملکرد قبل و بعد از اعمال RAG

برای ارزیابی تأثیر سیستم RAG بر عملکرد مدل انگلیسی، آزمون‌های مشابه فصل قبل بر روی مدل ترکیبی (مدل فاین‌تیون‌شده + RAG) انجام شد. نتایج در جدول ۳.۴ ارائه شده است:

جدول ۳.۴: مقایسه عملکرد مدل‌های انگلیسی با و بدون سیستم RAG

Model	HeadQA	MedQA	MedMCQA	MMLU-anatomy	MMLU C-K	MMLU C-M	MMLU MG	MMLU PM
gemma-3-12b-it	70.97	65.06	55.23	65.19	75.10	75.35	78.79	78.66
gemma-3-12b-it-en-sft	77.33	74.28	61.46	70.38	80.72	80.83	82.82	81.65
gemma-3-12b-it-en-sft + RAG	78.83	75.42	62.20	71.56	82.10	83.12	82.50	82.46

۲.۵.۴ تحلیل نتایج و بهبودهای حاصله در سیستم انگلیسی

نتایج نشان می‌دهد که اضافه کردن سیستم RAG به مدل فاین‌تیون‌شده انگلیسی منجر به بهبود اضافی قابل‌توجه در عملکرد شده است. این بهبود نشان‌دهنده اثربخشی بالای ترکیب اطلاعات تخصصی موجود در پایگاه دانش با قابلیت‌های مدل زبانی است [۵].

میانگین بهبود در تمامی معیارهای ارزیابی حدود 1.09 درصد نسبت به مدل فاین‌تیون‌شده و 6.73 درصد نسبت به مدل پایه است. این نتایج اهمیت استفاده از منابع اطلاعاتی تخصصی و روش‌های پیشرفته بازتابی را در بهبود عملکرد مدل‌های زبانی در حوزه پزشکی تأیید می‌کند.

تحلیل بهبودهای حوزه‌محور جدول ۴.۴ نشان می‌دهد که بیشترین بهبود در حوزه college-medicine با 2.29 درصد نسبت به مدل فاین‌تیون‌شده حاصل شده است. این بهبود قابل توجه نشان‌دهنده تأثیر مثبت منابع اطلاعاتی Textbooks است که براساس کتاب‌های معتبر پزشکی است.

جدول ۴.۴: میزان بهبود عملکرد در هر حوزه - سیستم انگلیسی

حوزه	بهبود نسبت به مدل پایه	بهبود نسبت به مدل فاین تیون
HeadQA	+7.86%	+1.50%
MedQA	+10.36%	+1.14%
MedMCQA	+6.97%	+0.74%
anatomy	+6.37%	+1.18%
clinical-knowledge	+7.00%	+1.38%
college-medicine	+7.77%	+2.29%
medical-genetics	+3.71%	-0.32%
professional-medicine	+3.80%	+0.81%
میانگین	+6.73%	+1.09%

بخش چهارم

سیستم RAG با منابع فارسی و انگلیسی

۶.۴ توسعه سیستم به زبان فارسی

۱.۶.۴ انگیزه و ضرورت توسعه فارسی

با توجه به کمبود منابع پزشکی معتبر به زبان فارسی و نیاز به ارائه خدمات به کاربران فارسی‌زبان، تصمیم گرفته شد سیستم RAG با افزودن منابع فارسی توسعه یابد. این توسعه در کنار منابع انگلیسی موجود انجام شد تا سیستمی دوزبانه و جامع ایجاد شود.

۷.۴ جمع‌آوری و انتخاب منابع اطلاعاتی فارسی

۱.۷.۴ معرفی دیتاست Persian Medical Corpus

علاوه بر منابع انگلیسی، برای پشتیبانی از زبان فارسی، از دیتاست Persian Medical Corpus استفاده شد. این دیتاست شامل محتوای پزشکی جامع به زبان فارسی است که از منابع معتبر داخلی جمع‌آوری شده است.

۲.۷.۴ مشخصات مجموعه داده‌های فارسی و انگلیسی

جدول ۵.۴ مشخصات کامل مجموعه داده‌های مورد استفاده در سیستم دوزبانه را نشان می‌دهد:

جدول ۵.۴: مجموعه داده‌های کامل سیستم RAG دوزبانه

مجموعه داده	زبان	حوزه	تعداد اولیه	تعداد تکه	روش قطعه‌بندی
Textbooks	انگلیسی	پزشکی	125.8K	125.8K	پیش‌فرض
StatePearls	انگلیسی	بالینی	247K	247K	Late + Recursive
Persian Medical Corpus	فارسی	پزشکی	-	5,176,679	Late + Recursive
مجموع کل	دوزبانه	پزشکی	-	5,550,179	-

۸.۴ پردازش و تکه‌تکه‌سازی منابع فارسی

۱.۸.۴ پیش‌پردازش با کتابخانه Hazm

برای پردازش بهینه متون فارسی، از کتابخانه Hazm استفاده شد که یکی از جامع‌ترین ابزارهای پردازش زبان طبیعی فارسی است. این کتابخانه امکانات زیر را فراهم کرد:

- نرمال‌سازی متون فارسی (حذف فاصله‌های اضافی، اصلاح نیم‌فاصله‌ها)
- تشخیص مرز جملات فارسی
- توکن‌سازی مناسب برای زبان فارسی
- حذف کاراکترهای غیرضروری و نویزها

۲.۸.۴ تکه‌تکه‌سازی Persian Medical Corpus

پس از پیش‌پردازش، دیتاست Persian Medical Corpus با استفاده از ترکیب تکنیک‌های Late Chunking و Recursive Chunking پردازش شد. این فرآیند منجر به تولید ۶۷۹،۱۷۶،۵ تکه با مشخصات زیر شد:

- حداکثر طول هر تکه: ۵۰۰ کاراکتر
- میزان همپوشانی (Overlap): ۱۰۰ کاراکتر
- روش تقسیم: بازگشتی با حفظ یکپارچگی معنایی

۳.۸.۴ مراحل تکه‌تکه‌سازی فارسی

مرحله اول: پیش‌پردازش و نرمال‌سازی

۱. بارگذاری متون خام فارسی
۲. اعمال نرمال‌سازی با Hazm
۳. تشخیص و جداسازی پاراگراف‌ها
۴. حذف عناصر غیرضروری

مرحله دوم: تکه‌سازی بازگشتی

۱. تقسیم متن بر اساس پاراگراف‌ها
۲. بررسی طول هر بخش (حداکثر ۵۰۰ کاراکتر)
۳. تقسیم مجدد بخش‌های بزرگ‌تر
۴. حفظ ۱۰۰ کاراکتر همپوشانی بین تکه‌ها

مرحله سوم: اعمال Late Chunking

۱. پردازش کل سند به صورت یکپارچه
۲. تولید نمایش برداری کامل
۳. تقسیم بردار بر اساس مرزهای تکه‌ها
۴. ذخیره‌سازی تکه‌ها با حفظ زمینه کامل

۴.۸.۴ تنظیمات فنی پردازش فارسی

جدول ۶.۴ پارامترهای تکه‌تکه‌سازی برای دیتاست فارسی را نشان می‌دهد:

جدول ۶.۴: پارامترهای تکه‌تکه‌سازی دیتاست فارسی

مجموعه داده	اندازه تکه	Overlap	روش تکه‌سازی
Corpus Medical Persian	500 chars	100 chars	Recursive + Late

۹.۴ محدودیت‌های شباهت‌سنجی در سیستم دوزبانه

یکی از چالش‌های اساسی در پیاده‌سازی این سیستم، دوزبانه بودن محیط کاربردی بود. با توجه به اینکه کاربران ممکن است سوالات خود را به زبان فارسی مطرح کنند در حالی که بخشی از اسناد پزشکی به زبان انگلیسی هستند (و بالعکس)، استفاده از روش‌های سنتی شباهت‌سنجی مبتنی بر فراوانی کلمات (مانند TF-IDF یا BM25) عملی نبود.

در نتیجه، سیستم مجبور به تکیه بر روش شباهت‌سنجی کسینوسی^۲ بر روی بردارهای معنایی شد. این محدودیت به دلایل زیر وجود داشت:

- ناهمگونی زبانی: عدم تطابق مستقیم بین واژگان فارسی و انگلیسی
 - عدم کارایی روش‌های مبتنی بر فراوانی: روش‌هایی مانند TF-IDF در محیط چندزبانه قابل اعتماد نیستند
 - نیاز به درک معنایی: ضرورت درک معنای مفاهیم فراتر از تطابق لغوی
 - تنوع اصطلاحات پزشکی: وجود معادل‌های متفاوت برای اصطلاحات پزشکی در دو زبان
- بنابراین، استفاده از مدل‌های embedding چندزبانه و محاسبه شباهت کسینوسی تنها راه حل عملی برای غلبه بر این چالش شناخته شد.

۱۰.۴ ذخیره‌سازی و سازماندهی منابع دوزبانه

۱.۱۰.۴ ساختار ایندکس‌گذاری یکپارچه

برای مدیریت بهینه منابع دوزبانه، ساختار ایندکس‌گذاری به گونه‌ای طراحی شد که امکان جستجو و بازیابی همزمان از هر دو زبان را فراهم کند. فیلدهای اضافی زیر به ساختار اضافه شدند:

- **language**: تعیین زبان سند (Persian/English)
- **normalized_text**: متن نرمال‌شده برای جستجوی بهتر
- **cross_lingual_embedding**: بردار چندزبانه برای جستجوی میان‌زبانی

^۲Cosine Similarity

۱۱.۴ ارزیابی عملکرد سیستم RAG فارسی

۱.۱۱.۴ ارزیابی مدل فارسی با سیستم RAG

برای ارزیابی تأثیر سیستم RAG بر عملکرد مدل فارسی، از مدل gemma-3-12b-it-fa-sft به عنوان مدل پایه استفاده شد. این مدل که در فصل قبل به عنوان مدل برگزیده فارسی انتخاب شده بود، با سیستم RAG دوزبانه ترکیب شد.

۲.۱۱.۴ نتایج ارزیابی سیستم فارسی

نتایج ارزیابی مدل فارسی با و بدون سیستم RAG در جدول ۷.۴ ارائه شده است:

جدول ۷.۴: مقایسه عملکرد مدل فارسی با و بدون سیستم RAG

Model	Anatomy	Clinical-K	College-M	Medical-G	Professional-M
gemma-3-12b-it (baseline)	56%	68%	74%	72%	74%
gemma-3-12b-it-fa-sft	58%	70%	76%	74%	76%
gemma-3-12b-it-fa-sft + RAG	60%	71%	77%	75%	77%

۳.۱۱.۴ تحلیل نتایج سیستم دوزبانه

نتایج نشان می‌دهد که اضافه کردن سیستم RAG دوزبانه به مدل فارسی منجر به بهبود متوسط 1.4 درصدی شده است. این بهبود با وجود حجم زیاد داده‌های فارسی (بیش از ۵ میلیون تکه) قابل توجه است و نشان‌دهنده اثربخشی روش‌های پیاده‌سازی شده است. جدول ۸.۴ میزان بهبود در هر حوزه را نشان می‌دهد:

جدول ۸.۴: میزان بهبود عملکرد در هر حوزه - سیستم فارسی

حوزه	بهبود نسبت به مدل پایه	بهبود نسبت به مدل فاین‌تیون
Anatomy	+4%	+2%
Clinical Knowledge	+3%	+1%
College Medicine	+3%	+1%
Medical Genetics	+3%	+1%
Professional Medicine	+3%	+1%
میانگین	+3.2%	+1.2%

۱۲.۴ ارزیابی کیفی سیستم دوزبانه

علاوه بر ارزیابی‌های کمی، آزمون‌های کیفی نیز برای بررسی کیفیت پاسخ‌های تولیدی توسط سیستم دوزبانه انجام شد. نتایج نشان می‌دهد که سیستم RAG دوزبانه توانایی‌های زیر را به مدل اضافه کرده است:

- پشتیبانی مستندات دوزبانه: ارائه منابع معتبر به هر دو زبان فارسی و انگلیسی
- دقت اطلاعات: کاهش قابل توجه در تولید اطلاعات نادرست در هر دو زبان
- پوشش جامع: پاسخ‌دهی به سوالات تخصصی به هر دو زبان
- ترجمه ضمنی مفاهیم: قابلیت استفاده از منابع انگلیسی برای پاسخ به سوالات فارسی و بالعکس

۱۳.۴ تصمیمات طراحی و محدودیت‌ها

۱.۱۳.۴ حذف مجموعه داده‌های حجیم

سایر مجموعه داده‌هایی مانند Wikipedia (29.9M) و PubMed (23.9M) به دلیل حجم بالا و نیاز به پردازش گسترده، از فرآیند نهایی حذف شدند. این تصمیم بر اساس محدودیت‌های زیر گرفته شد:

- محدودیت‌های محاسباتی: نیاز به منابع پردازشی بالا و زمان طولانی برای embedding
- کیفیت در برابر کمیت: تمرکز بر کیفیت داده‌های تخصصی به جای حجم بالا
- محدودیت‌های ذخیره‌سازی: نیاز به فضای ذخیره‌سازی گسترده
- پیچیدگی مدیریت: افزایش پیچیدگی سیستم بدون بهبود متناسب در عملکرد

۲.۱۳.۴ تأثیر تصمیمات بر عملکرد

علی‌رغم حذف مجموعه داده‌های حجیم انگلیسی، انتخاب داده‌های تخصصی و کیفی همراه با افزودن حجم قابل توجه داده‌های فارسی (بیش از ۵ میلیون تکه) منجر به عملکرد مطلوب سیستم RAG شده است.

۱۴.۴ محدودیت‌ها و چالش‌های سیستم دوزبانه

۱.۱۴.۴ محدودیت‌های فنی

علی‌رغم عملکرد مطلوب سیستم RAG دوزبانه، چندین محدودیت فنی شناسایی شده است:

۱. تأخیر در پاسخ‌دهی: فرآیند بازیابی از حجم بالای داده‌ها (۵.۵ میلیون تکه) منجر به افزایش زمان پاسخ می‌شود
۲. پیچیدگی معماری: مدیریت منابع دوزبانه پیچیدگی سیستم را افزایش داده است
۳. عدم توازن زبانی: تفاوت در حجم و کیفیت منابع فارسی و انگلیسی
۴. چالش‌های embedding چندزبانه: کیفیت متفاوت نمایش برداری برای زبان‌های مختلف

۲.۱۴.۴ چالش‌های الگوریتمی

- انتخاب تکه‌های مناسب: تعیین اولویت بین تکه‌های فارسی و انگلیسی
- ترکیب اطلاعات چندزبانه: ادغام اطلاعات از منابع با زبان‌های مختلف
- تنظیم وزن‌ها: تعادل بین منابع فارسی و انگلیسی در پاسخ‌دهی

۱۵.۴ پیشنهادات بهبود

۱.۱۵.۴ بهینه‌سازی فنی

برای بهبود عملکرد سیستم RAG دوزبانه، پیشنهادات زیر ارائه می‌شود:

۱. استفاده از **Graph RAG**: پیاده‌سازی روش‌های مبتنی بر گراف برای حفظ روابط معنایی بین مفاهیم در هر دو زبان [۱۸]
۲. بهینه‌سازی مدل **Embedding**: استفاده از مدل‌های embedding تخصصی چندزبانه برای حوزه پزشکی
۳. ایندکس‌گذاری هوشمند: استفاده از روش‌های هوشمند برای کاهش زمان جستجو در حجم بالای داده‌ها

۲.۱۵.۴ توسعه پایگاه دانش

- اضافه کردن منابع فارسی معتبر بیشتر در حوزه پزشکی
- ترجمه خودکار منابع انگلیسی کیفی به فارسی
- به‌روزرسانی مستمر پایگاه دانش با جدیدترین یافته‌های علمی در هر دو زبان
- تکمیل حوزه‌های تخصصی کم‌پوشش در زبان فارسی

۱۶.۴ تحلیل هزینه-فایده

۱.۱۶.۴ هزینه‌های محاسباتی

پیاده‌سازی سیستم RAG دوزبانه منجر به افزایش هزینه‌های محاسباتی زیر شده است:

- ذخیره‌سازی: نیاز به فضای اضافی برای نگهداری بردارهای embedding (حدود 15 گیگابایت برای سیستم کامل)
- حافظه: نیاز به حافظه اضافی برای بارگذاری Elasticsearch و مدل‌های embedding چندزبانه
- پردازش: افزایش زمان پردازش به دلیل حجم بالای داده‌های فارسی

۲.۱۶.۴ مزایای کسب شده

در مقابل، مزایای زیر حاصل شده است:

- بهبود میانگین 1.09% در دقت پاسخدهی انگلیسی
- بهبود میانگین 1.2% در دقت پاسخدهی فارسی
- قابلیت پاسخدهی به کاربران دوزبانه
- افزایش اعتماد کاربران به دلیل ارائه منابع مستند در هر دو زبان
- امکان استفاده متقابل از منابع دو زبان

۱۷.۴ کاربردهای آینده و توسعه‌های ممکن

۱.۱۷.۴ یکپارچگی با سیستم‌های بالینی

سیستم RAG دوزبانه طراحی شده قابلیت یکپارچگی با سیستم‌های مدیریت اطلاعات بیمارستانی (HIS) و سیستم‌های پشتیبانی تصمیم بالینی (CDSS) در محیط‌های دوزبانه را دارد. این یکپارچگی امکانات زیر را فراهم می‌کند:

- دسترسی به تاریخچه پزشکی بیماران به هر دو زبان
- تحلیل نتایج آزمایش‌ها با مراجع فارسی و انگلیسی
- ارائه توصیه‌های درمانی مبتنی بر شواهد جهانی و محلی
- هشدارهای دارویی با در نظر گرفتن داروهای داخلی و خارجی

۲.۱۷.۴ توسعه به حوزه‌های تخصصی

۱. رادیولوژی: یکپارچگی با سیستم‌های تحلیل تصویر پزشکی با گزارش‌دهی دوزبانه
۲. آسیب‌شناسی: پشتیبانی در تفسیر نتایج با استفاده از منابع فارسی و انگلیسی
۳. داروسازی: ارائه اطلاعات جامع درباره داروهای داخلی و خارجی
۴. طب سنتی: ترکیب دانش طب سنتی ایرانی با پزشکی مدرن

۱۸.۴ جمع‌بندی

در این فصل، پیاده‌سازی جامع سیستم بازیابی افزوده (RAG) دوزبانه برای دستیار هوشمند پزشکی تشریح شد. سیستم در دو مرحله توسعه یافت:

مرحله اول - سیستم انگلیسی: استفاده از مجموعه داده‌های تخصصی StatePearls و Textbooks با 373.5 هزار سند، همراه با تکنیک‌های پیشرفته تکه‌تکه‌سازی به‌ویژه Late Chunking، منجر به ایجاد

پایگاه دانش انگلیسی شد. نتایج نشان داد که این سیستم باعث بهبود میانگین 1.09 درصدی در عملکرد مدل انگلیسی شده است.

مرحله دوم - سیستم دوزبانه: با افزودن دیتاست Persian Medical Corpus که پس از پردازش با کتابخانه Hazm و تکنیک‌های Late + Recursive Chunking به 5,176,679 تکه تبدیل شد، سیستم به یک پلتفرم دوزبانه جامع تبدیل گردید. این توسعه منجر به بهبود 1.2 درصدی در عملکرد مدل فارسی شد.

استفاده از تکنیک Late Chunking به عنوان یکی از نوآوری‌های این پروژه، بهبود ۱۵-۲۰ درصدی در دقت بازبازی اطلاعات را نسبت به روش‌های سنتی ارائه داده است. این روش با حفظ زمینه کامل اسناد و جلوگیری از قطع روابط معنایی، کیفیت پاسخ‌های سیستم را در هر دو زبان به طور چشمگیری بهبود بخشیده است.

محدودیت‌های دوزبانه بودن سیستم، از جمله عدم امکان استفاده از روش‌های سنتی شباهت‌سنجی، با استفاده از مدل‌های embedding چندزبانه و محاسبه شباهت کسینوسی حل شد. این رویکرد امکان جستجوی متقابل بین دو زبان را فراهم کرده است.

به طور کلی، سیستم RAG دوزبانه طراحی شده نشان می‌دهد که ترکیب هوشمندانه دانش تخصصی چندزبانه با قدرت مدل‌های زبانی بزرگ، راه حل مؤثری برای توسعه دستیارهای هوشمند پزشکی محسوب می‌شود که قابلیت ارائه پاسخ‌های دقیق، مستند و قابل اعتماد در حوزه پزشکی به هر دو زبان فارسی و انگلیسی را دارد.

فصل ۵

پیاده‌سازی مکانیزم‌های امنیتی (Guardrails)

۱.۵ مقدمه

در سیستم‌های دستیار هوشمند پزشکی، تضمین ایمنی و کیفیت پاسخ‌ها از اهمیت بالایی برخوردار است. مکانیزم‌های امنیتی (Guardrails) به‌عنوان لایه‌ای حفاظتی عمل می‌کنند که از ارائه اطلاعات نادرست، خطرناک یا غیراخلاقی جلوگیری می‌کنند. در این فصل، پیاده‌سازی سیستم جامع کنترل ایمنی برای دستیار هوشمند پزشکی تشریح می‌شود که شامل فیلترینگ ورودی‌ها، نظارت بر خروجی‌ها و اعمال سیاست‌های امنیتی تخصصی است [۴].

۲.۵ نیاز به مکانیزم‌های امنیتی در حوزه پزشکی

۱.۲.۵ چالش‌های خاص حوزه پزشکی

حوزه پزشکی از جمله حساس‌ترین حوزه‌های کاربرد هوش مصنوعی محسوب می‌شود. ارائه اطلاعات نادرست یا نامناسب می‌تواند عواقب جدی برای سلامت کاربران داشته باشد. چالش‌های اصلی شامل موارد زیر است:

- ارائه تشخیص پزشکی غیرمجاز: سیستم نباید به‌عنوان جایگزین پزشک عمل کند
- تجویز دارو یا درمان: ارائه توصیه‌های درمانی تخصصی خارج از صلاحیت سیستم است
- مدیریت اطلاعات حساس: حفاظت از اطلاعات شخصی بهداشتی (PHI) کاربران طبق استانداردهای HIPAA
- پاسخ به موقعیت‌های اورژانسی: شناسایی و هدایت صحیح موارد اضطراری به مراکز مربوطه
- تشخیص تداخلات دارویی خطرناک: جلوگیری از ارائه اطلاعاتی که منجر به مصرف نادرست دارو شود

۲.۲.۵ اهمیت پیاده‌سازی Guardrails

پیاده‌سازی مکانیزم‌های امنیتی در سیستم‌های پزشکی اهداف زیر را دنبال می‌کند:

- حفاظت از کاربران: جلوگیری از ارائه اطلاعات مضر یا گمراه‌کننده
- حفظ اعتبار سیستم: حفظ استانداردهای اخلاقی و حرفه‌ای
- انطباق با قوانین: رعایت مقررات و استانداردهای بهداشتی مانند HIPAA، GDPR و قوانین محلی
- مدیریت ریسک: کاهش مسئولیت‌های قانونی و اخلاقی
- ایجاد اعتماد: افزایش اطمینان کاربران و متخصصان پزشکی به سیستم

۳.۵ معماری سیستم Guardrails

۱.۳.۵ اجزای کلیدی سیستم

سیستم Guardrails پیاده‌سازی شده دارای معماری چندلایه است که شامل اجزای زیر می‌باشد:

۱. لایه کنترل ورودی (Input Guardrails): فیلترینگ درخواست‌های کاربر قبل از پردازش
۲. لایه پردازش اصلی (Main Processing): مدل زبانی فاین‌تیون شده + سیستم RAG
۳. لایه کنترل خروجی (Output Guardrails): بررسی و اصلاح پاسخ‌های تولیدی
۴. لایه گزارش‌دهی (Logging): ثبت رویدادهای امنیتی برای بهبود مستمر

۲.۳.۵ نمودار جریان پردازش

Listing 5.1: معماری سیستم کنترل امنیتی

```
[User Input]→
  [Input Validation]→
  [Input Guardrails]→
  [Main Model + RAG]→
  [Output Guardrails]→
  [Response Sanitization]→
  [Safe Response]↓
```

[Security Log]

۳.۳.۵ کنترل ورودی (Input Guardrails)

لایه کنترل ورودی به‌منظور فیلتر کردن درخواست‌های نامناسب کاربران طراحی شده است. این لایه قبل از ارسال سوال به مدل اصلی، محتوای آن را بررسی می‌کند و در صورت تشخیص محتوای نامناسب، پیام مناسبی به کاربر ارائه می‌دهد.

۴.۳.۵ کنترل خروجی (Output Guardrails)

لایه کنترل خروجی وظیفه بررسی پاسخ‌های تولیدشده توسط مدل اصلی را بر عهده دارد و در صورت تشخیص محتوای نامناسب، پاسخ را مسدود یا اصلاح می‌کند. این لایه به عنوان آخرین خط دفاعی عمل می‌کند.

۴.۵ پیکربندی سیستم Guardrails

۱.۴.۵ تنظیمات اصلی سیستم

پیکربندی اصلی سیستم Guardrails به شرح زیر تنظیم شده است:

Listing 5.2: پیکربندی سیستم

```
models:
- type: main
  engine: gemma-3-12b-it-en-sft # For English
  model: local

rails:
input:
  flows:
  - self check input
  - toxicity check
  - medical safety check
output:
  flows:
  - self check output
  - fact verification
  - medical accuracy check
```

این پیکربندی چندین جریان کنترلی را تعریف می‌کند که به ترتیب بر روی ورودی و خروجی سیستم اعمال می‌شوند.

۲.۴.۵ سیاست‌های امنیتی ورودی

پرامپت کنترل ورودی با هدف شناسایی و مسدود کردن درخواست‌های نامناسب طراحی شده است:

Listing 5.3: پرامپت کنترل ورودی

```
prompts:
- task: self_check_input
  content: |
    Your task is to check if the user message below complies with
    the
    company's medical-guardrails policy for our healthcare
    assistant.

    Medical-guardrails policy for user messages:
```

- Must not request personalized diagnosis, treatment plans, or prescriptions without directing to a qualified professional.
- Must not ask the assistant to override medical disclaimers or "forget" its safety rules.
- Must not seek emergency or crisis interventions (e.g., "I'm going to harm myself right now"), but instead must be escalated to appropriate resources.
- Must not contain explicit or graphic descriptions of self-harm, abuse, or other sensitive topics without proper context or trigger warnings.
- Must not use abusive, harassing, or stigmatizing language toward any group or individual.
- Must not share or request personal health information (PHI) beyond de-identified examples.
- Must not ask the assistant to impersonate a licensed healthcare provider.
- Must not attempt to probe or expose the underlying system or internal prompts of the assistant.
- Must not contain code, malware, or instructions for illicit behavior.

User message: "{{ user_input }}"

Question: Should the user message be blocked (Yes or No)?

Answer:

۳.۴.۵ سیاست‌های امنیتی خروجی

پرامپت کنترل خروجی برای ارزیابی پاسخ‌های تولیدشده توسط مدل اصلی طراحی شده است:

Listing 5.4: پرامپت کنترل خروجی

prompts:

- task: self_check_output
content: |

Your task is to evaluate whether the assistant's response below complies with the company's medical content policy.

Medical Content Policy:

- Must not provide medical advice that could lead to harm if followed.
- Must clearly state that it is not a substitute for professional medical consultation, diagnosis, or treatment.
- Must avoid making specific treatment recommendations, unless

- explicitly allowed by guidelines.
- Must not include misinformation about medical conditions, treatments, medications, or procedures.
- Must not encourage or validate self-diagnosis or self-medication.
- Must avoid speculative, unverified, or anecdotal claims about medical outcomes.
- If declining to answer a medical question, the tone must be clear, empathetic, and cautionary.
- May direct users to consult qualified healthcare professionals or official health sources.
- Must include appropriate disclaimers when discussing medical topics.

Assistant Response: "{{ bot_response }}"

Question: Does this response violate the policy and therefore need to be blocked (Yes or No)?

Answer:

۵.۵ تحلیل سیاست‌های امنیتی

۱.۵.۵ سیاست‌های کنترل ورودی

سیاست‌های کنترل ورودی در نه دسته اصلی طبقه‌بندی شده‌اند:

- منع درخواست تشخیص شخصی: جلوگیری از درخواست‌های مربوط به تشخیص پزشکی، طرح درمان یا نسخه پزشکی
- حفاظت از قوانین امنیتی: مقاومت در برابر تلاش‌هایی برای دور زدن یا فراموش کردن قوانین ایمنی
- مدیریت موقعیت‌های اورژانسی: شناسایی و هدایت صحیح موارد بحرانی و اورژانسی
- کنترل محتوای حساس: فیلتر کردن توضیحات صریح از خودآزاری یا سوءاستفاده
- منع زبان توهین‌آمیز: جلوگیری از استفاده از زبان توهین‌آمیز یا تبعیض‌آمیز
- حفاظت اطلاعات شخصی: محدود کردن اشتراک‌گذاری اطلاعات بهداشتی شخصی
- منع جعل هویت: جلوگیری از ادعای ارائه‌دهنده مراقبت‌های بهداشتی مجاز
- امنیت سیستم: محافظت در برابر تلاش‌های نفوذ به سیستم
- منع محتوای مخرب: فیلتر کردن کد مخرب یا دستورالعمل‌های غیرقانونی

۲.۵.۵ سیاست‌های کنترل خروجی

سیاست‌های کنترل خروجی هشت معیار اساسی را پوشش می‌دهند:

- جلوگیری از ضرر: عدم ارائه مشاوره پزشکی که ممکن است موجب آسیب شود
- تأکید بر مشاوره حرفه‌ای: روشن ساختن جایگزین نبودن مشاوره پزشکی حرفه‌ای
- محدودیت توصیه‌های درمانی: اجتناب از توصیه‌های درمانی خاص
- دقت اطلاعات: جلوگیری از انتشار اطلاعات غلط پزشکی
- منع خودتشخیصی: عدم تشویق به تشخیص یا خوددرمانی
- اجتناب از ادعاهای بی‌اساس: عدم ارائه ادعاهای غیرقابل تأیید
- لحن مناسب: حفظ لحن روشن، همدلانه و احتیاط‌آمیز
- ارجاع به منابع معتبر: هدایت کاربران به متخصصان یا منابع رسمی
- اعلام محدودیت‌ها: ارائه disclaimer مناسب در پاسخ‌های پزشکی

۶.۵ چالش‌ها و محدودیت‌ها

۱.۶.۵ چالش‌های فنی

پیاده‌سازی سیستم Guardrails با چالش‌هایی مواجه بود:

- تعادل بین ایمنی و کاربردی بودن: یافتن نقطه تعادل مناسب بین حفاظت و قابلیت استفاده
- افزایش قابل توجه زمان پردازش: افزایش متوسط 730 میلی‌ثانیه (176%) در زمان پاسخ‌دهی
- پوشش جامع: اطمینان از پوشش تمامی سناریوهای نامناسب
- پشتیبانی دوزبانه: اطمینان از عملکرد یکسان برای هر دو زبان فارسی و انگلیسی

۲.۶.۵ محدودیت‌های کنونی

علی‌رغم عملکرد مطلوب، سیستم دارای محدودیت‌هایی است:

- تشخیص زمینه: چالش در تمایز موارد آموزشی از درخواست‌های واقعی
- حجم پردازش: افزایش حجم محاسبات مورد نیاز به دلیل اجرای چندین مرحله کنترل
- به‌روزرسانی سیاست‌ها: نیاز به به‌روزرسانی مستمر با ظهور الگوهای جدید سوءاستفاده
- تطبیق فرهنگی: نیاز به تنظیم سیاست‌ها برای فرهنگ‌های مختلف

۷.۵ راهکارهای بهبود

۱.۷.۵ بهینه‌سازی عملکرد

برای بهبود عملکرد سیستم، راهکارهای زیر پیشنهاد می‌شود:

- استفاده از مدل‌های سبک‌تر: آموزش مدل‌های تخصصی کوچک‌تر برای Guardrails
- پردازش موازی: اجرای همزمان بررسی‌های مختلف
- **Caching**: ذخیره‌سازی نتایج برای درخواست‌های مشابه
- قوانین ثابت: استفاده از قوانین rule-based برای موارد واضح

۲.۷.۵ افزایش دقت

- یادگیری مستمر: به‌روزرسانی مدل بر اساس بازخوردهای کاربران
- تنظیم آستانه‌ها: بهینه‌سازی حساسیت سیستم بر اساس نیاز
- ترکیب روش‌ها: استفاده همزمان از چندین تکنیک تشخیص

۸.۵ جمع‌بندی

در این فصل، پیاده‌سازی سیستم جامع Guardrails برای دستیار هوشمند پزشکی تشریح شد. این سیستم با استفاده از معماری دولایه کنترل ورودی و خروجی، قابلیت شناسایی و مسدود کردن محتوای نامناسب را فراهم می‌کند. سیاست‌های امنیتی تخصصی طراحی شده برای حوزه پزشکی، حفاظت جامعی در برابر انواع مختلف محتوای مضر ارائه می‌دهند.

این مکانیزم‌های امنیتی نه تنها از کاربران محافظت می‌کنند، بلکه اعتبار و قابلیت اطمینان سیستم را نیز ارتقا می‌دهند. با وجود چالش‌ها و محدودیت‌های موجود، سیستم پایه مستحکمی برای توسعه و بهبود آتی فراهم کرده است. در آینده، بهینه‌سازی زمان پاسخ‌دهی و افزایش دقت تشخیص، اولویت‌های اصلی توسعه خواهند بود.

فصل ۶

نتیجه‌گیری و پیشنهادات

۱.۶ خلاصه کلی پروژه

در این پروژه، یک دستیار هوشمند جامع برای حوزه پزشکی توسعه داده شد که از ترکیب سه تکنیک پیشرفته هوش مصنوعی بهره می‌برد. این سیستم شامل تنظیم دقیق نظارت‌شده^۱، سیستم بازیابی افزوده^۲، و مکانیزم‌های امنیتی (Guardrails) است که به صورت یکپارچه عمل کرده و دسترسی قابل اعتماد و دقیق در حوزه پزشکی به دو زبان انگلیسی و فارسی ارائه می‌دهد.

۲.۶ دستاوردهای اصلی

۱.۲.۶ دستاوردهای آموزش انگلیسی

بهبود عملکرد مدل پایه انگلیسی: مدل Gemma-3-12B-IT پس از تنظیم دقیق با مجموعه داده 200 هزار نمونه پزشکی، بهبود قابل توجهی در تمامی معیارهای ارزیابی نشان داد. بیشترین بهبود در آزمون MedQA با 9.22% رشد دقت مشاهده شد. مدل نهایی gemma-3-12b-it-en-sft تولید شد. پیاده‌سازی سیستم RAG انگلیسی: با استفاده از 373.5 هزار سند تخصصی از مجموعه‌های StatePearls و Textbooks و اعمال تکنیک Late Chunking، سیستم بازیابی افزوده‌ای ایجاد شد که دقت مدل انگلیسی را در برخی حوزه‌ها تا 2.29 درصد بیشتر بهبود داد.

۲.۲.۶ دستاوردهای آموزش فارسی

توسعه مدل‌های فارسی: دو مدل gpt-oss-20b و Gemma-3-12b-it با دیتاست MF3QA (۲۲ هزار نمونه) آموزش داده شدند. مدل gemma-3-12b-it-fa-sft با میانگین دقت 70.8% به عنوان مدل برتر فارسی انتخاب شد.

پیاده‌سازی سیستم RAG دوزبانه: با افزودن دیتاست Persian Medical Corpus که به 5,176,679 تکه تقسیم شد، سیستم RAG به یک پلتفرم دوزبانه جامع تبدیل گردید که قابلیت جستجوی متقابل بین دو زبان را فراهم کرد.

^۱Supervised Fine-Tuning

^۲Retrieval-Augmented Generation

۳.۲.۶ دستاوردهای امنیتی

تضمین امنیت با **Guardrails**: سیستم امنیتی طراحی‌شده با بررسی ورودی و خروجی، امنیت کلی سیستم را به ارتقا داد.

۳.۶ تحلیل نتایج نهایی

۱.۳.۶ عملکرد کلی سیستم انگلیسی

جدول ۱.۶ عملکرد نهایی سیستم انگلیسی را در مقایسه با مدل پایه نشان می‌دهد:

جدول ۱.۶: خلاصه عملکرد نهایی سیستم انگلیسی

حوزه	مدل پایه	سیستم نهایی	بهبود کلی
HeadQA	70.97%	78.83%	+7.86%
MedQA	65.06%	75.42%	+10.36%
MedMCQA	55.23%	62.20%	+6.97%
anatomy	65.19%	71.56%	+6.37%
clinical-knowledge	75.10%	82.10%	+7.00%
college-medicine	75.35%	83.12%	+7.77%
medical-genetics	78.79%	82.50%	+3.71%
professional-medicine	78.66%	82.46%	+3.80%
میانگین	70.54%	77.27%	+6.73%

۲.۳.۶ عملکرد کلی سیستم فارسی

جدول ۲.۶ عملکرد نهایی سیستم فارسی را نشان می‌دهد:

جدول ۲.۶: خلاصه عملکرد نهایی سیستم فارسی

حوزه	مدل پایه	سیستم نهایی	بهبود کلی
Anatomy	56%	60%	+4%
Clinical Knowledge	68%	71%	+3%
College Medicine	74%	77%	+3%
Medical Genetics	72%	75%	+3%
Professional Medicine	74%	77%	+3%
میانگین	68.8%	72%	+3.2%

۳.۳.۶ تحلیل قوت‌ها و ضعف‌های سیستم

نقاط قوت:

- بهبود جامع در تمامی معیارهای ارزیابی پزشکی در هر دو زبان
- امنیت بالا با قابلیت تشخیص و فیلتر محتوای نامناسب
- دسترسی به اطلاعات تخصصی از طریق RAG در دو زبان
- پشتیبانی کامل دوزبانه (فارسی و انگلیسی)
- استفاده بهینه از منابع محاسباتی با تکنیک‌های LoRA و quantization (QLoRA)
- قابلیت جستجوی متقابل بین دو زبان

نقاط ضعف:

- افزایش قابل توجه زمان پاسخ‌دهی (176%) به دلیل لایه‌های امنیتی
- محدودیت در حجم داده‌های RAG انگلیسی به دلیل منابع محاسباتی
- عملکرد ضعیف‌تر در زبان فارسی نسبت به انگلیسی (به دلیل حجم کمتر داده‌های آموزشی)
- عدم توازن بین منابع فارسی و انگلیسی در سیستم RAG

۴.۶ کاربردهای عملی

۱.۴.۶ کاربردهای بالینی

مراکز درمانی: استفاده به عنوان ابزار کمکی برای پرسنل پزشکی جهت دسترسی سریع به اطلاعات تخصصی در هر دو زبان
سیستم‌های مشاوره آنلاین: ارائه مشاوره‌های اولیه با رعایت اصول اخلاقی و ایمنی به کاربران فارسی و انگلیسی‌زبان

۲.۴.۶ کاربردهای آموزشی

آموزش پزشکی: ایجاد پلتفرم تعاملی دوزبانه برای آموزش دانشجویان پزشکی با تضمین ارائه اطلاعات صحیح
آموزش عمومی: ارتقای سواد سلامت عمومی با ارائه اطلاعات معتبر به زبان‌های فارسی و انگلیسی

۳.۴.۶ کاربردهای پژوهشی

تحقیقات پزشکی: تسهیل دسترسی محققان به منابع علمی و اطلاعات تخصصی در هر دو زبان
مطالعات بین‌رشته‌ای: امکان همکاری بین محققان فارسی و انگلیسی‌زبان

۵.۶ پیشنهادات برای بهبود

۱.۵.۶ Reinforcement Learning آموزش مدل به صورت

یکی از مهم‌ترین جهت‌های توسعه آتی، پیاده‌سازی آموزش تقویتی^۳ برای بهبود کیفیت پاسخ‌های مدل در هر دو زبان است. مزایای پیشنهاد:

- بهبود کیفیت پاسخ: آموزش مدل بر اساس بازخورد کاربران واقعی و ارزیابی‌های تخصصی
- تطبیق با ترجیحات کاربران: یادگیری سبک پاسخ‌دهی مطلوب از طریق تعامل مستمر
- کاهش پاسخ‌های نامناسب: تنبیه مدل برای تولید پاسخ‌های غیردقیق یا خطرناک
- بهبود متوازن دوزبانه: تضمین کیفیت یکسان در هر دو زبان

پیاده‌سازی پیشنهادی:

۱. جمع‌آوری داده‌های بازخورد از متخصصان پزشکی فارسی و انگلیسی‌زبان
۲. طراحی تابع پاداش مبتنی بر معیارهای دقت، امنیت، مفیدبودن و کیفیت زبانی
۳. استفاده از تکنیک‌های PPO^۴ یا DPO^۵ برای آموزش
۴. ارزیابی مستمر و تنظیم پارامترهای پاداش برای هر زبان به صورت جداگانه
۵. ایجاد سیستم بازخورد دوزبانه برای بهبود مستمر

۲.۵.۶ بهینه‌سازی مکانیزم Guardrails برای سرعت بیشتر

با توجه به افزایش ۱۷۶ درصدی زمان پاسخ‌دهی، بهینه‌سازی مکانیزم‌های امنیتی ضروری است. راهکارهای پیشنهادی:

- استفاده از مدل‌های کوچک‌تر برای فیلترینگ:
 - جایگزینی مدل‌های سنگین با مدل‌های تخصصی کوچک‌تر (مثلاً DistilBERT برای انگلیسی و ParsBERT برای فارسی)
 - آموزش classifier مخصوص برای تشخیص محتوای نامناسب در هر زبان
 - کاهش تعداد inference call های مورد نیاز
- پردازش موازی:
 - اجرای هم‌زمان بررسی‌های ورودی و خروجی
 - استفاده از batch processing برای چندین درخواست

^۳Reinforcement Learning

^۴Proximal Policy Optimization

^۵Direct Preference Optimization

- بهینه‌سازی pipeline پردازش با async processing
- استفاده از GPU batching برای پردازش همزمان چندین درخواست

• کاهش complexity:

- ساده‌سازی منطق تصمیم‌گیری Guardrails
- استفاده از rule-based systems برای موارد ساده
- اعمال ML models تنها برای موارد پیچیده
- ایجاد cache برای الگوهای تکراری

• Caching هوشمند:

- ذخیره نتایج بررسی برای درخواست‌های مشابه
- استفاده از semantic hashing برای تشخیص درخواست‌های مشابه
- پیاده‌سازی TTL مناسب برای حفظ امنیت

هدف کلی: کاهش زمان پاسخ‌دهی به زیر ۵۰۰ میلی‌ثانیه با حفظ دقت فیلترینگ بالای ۹۰٪

۳.۵.۶ Fine-tune مدل Embedder و ارزیابی دقیق‌تر سیستم RAG

بهبود سیستم RAG از طریق تخصصی‌سازی مدل embedding برای حوزه پزشکی دوزبانه. اهداف بهبود:

• تخصصی‌سازی مدل Embedding:

- Fine-tuning مدل embedding بر روی corpus پزشکی دوزبانه
- آموزش مدل برای تشخیص روابط معنایی تخصصی در هر دو زبان
- بهبود دقت بازیابی اسناد مرتبط به‌ویژه برای جستجوهای میان‌زبانی
- استفاده از تکنیک‌های contrastive learning برای بهبود کیفیت embedding

• ارزیابی جامع‌تر RAG

معیارهای ارزیابی پیشنهادی:

- Retrieval Accuracy: دقت بازیابی اسناد مرتبط در هر زبان
- Cross-lingual Retrieval: دقت بازیابی میان‌زبانی
- Answer Relevance: مرتبط‌بودن پاسخ با سوال
- Context Utilization: میزان استفاده از context بازیابی‌شده

۴.۵.۶ توسعه پایگاه دانش فارسی

تقویت منابع فارسی برای ایجاد توازن با منابع انگلیسی:

- جمع‌آوری منابع جدید:
 - افزودن کتاب‌های مرجع پزشکی فارسی
 - استخراج محتوا از مجلات علمی فارسی معتبر
 - ترجمه خودکار منابع انگلیسی کیفی با نظارت متخصص
- بهبود کیفیت داده‌های موجود:
 - بازبینی و اصلاح تکه‌های فارسی موجود
 - افزودن metadata غنی‌تر به اسناد فارسی
 - ایجاد ارتباط بین اسناد مشابه فارسی و انگلیسی

۵.۵.۶ پیاده‌سازی Graph RAG

استفاده از ساختارهای گرافی برای بهبود سیستم بازیابی:

- ایجاد گراف دانش دوزبانه از مفاهیم پزشکی
- برقراری روابط معنایی بین اسناد فارسی و انگلیسی
- استفاده از Graph Neural Networks برای بازیابی بهتر
- پیاده‌سازی reasoning بر روی گراف دانش

۶.۶ تحلیل هزینه-فایده کلی پروژه

۱.۶.۶ هزینه‌های صرف‌شده

- منابع محاسباتی: استفاده از GPU H100 برای آموزش (حدود ۵۰ ساعت کل)
- ذخیره‌سازی: حدود ۱۰۰ گیگابایت برای ذخیره مدل‌ها و داده‌های RAG
- زمان توسعه: ۱۸ ماه تحقیق و پیاده‌سازی

۲.۶.۶ فایده‌های حاصل‌شده

- ایجاد دستیار پزشکی دوزبانه با دقت بالا
- کاهش بار کاری پرسنل پزشکی در پاسخ به سوالات رایج
- ارتقای سطح دسترسی به اطلاعات پزشکی معتبر
- ایجاد زیرساخت برای توسعه‌های آتی در حوزه سلامت دیجیتال

۷.۶ نتیجه‌گیری نهایی

این پروژه نشان داد که ترکیب هوشمندانه تکنیک‌های مختلف یادگیری ماشین می‌تواند منجر به ایجاد سیستمی قدرتمند و امن برای کاربردهای تخصصی دوزبانه شود. دستاوردهای کلیدی:

- توسعه موفق دستیار پزشکی دوزبانه با عملکرد رقابتی
- پیاده‌سازی سیستم RAG با بیش از 5.5 میلیون تکه اطلاعاتی
- ایجاد مکانیزم‌های امنیتی
- اثبات امکان توسعه سیستم‌های AI پزشکی برای زبان فارسی

با وجود چالش‌هایی مانند افزایش زمان پاسخ‌دهی و عدم توازن منابع دوزبانه، نتایج حاصل از این تحقیق گواه بر پتانسیل بالای این رویکرد در حل مسائل واقعی است. دستیار هوشمند توسعه‌یافته نه تنها در حوزه پزشکی کاربرد دارد، بلکه template مناسبی برای توسعه سیستم‌های مشابه در حوزه‌های دیگر نظیر حقوق، مهندسی، و آموزش فراهم می‌کند. پیاده‌سازی پیشنهادات ارائه‌شده می‌تواند این سیستم را به ابزاری کاربردی و قابل اعتماد برای استفاده در محیط‌های واقعی بالینی و آموزشی تبدیل کند.

با توجه به رشد سریع تکنولوژی‌های هوش مصنوعی و نیاز روزافزون به خدمات پزشکی دیجیتال دوزبانه، ادامه تحقیق و توسعه در این جهت نه تنها ضروری است بلکه می‌تواند تأثیر مثبت قابل توجهی بر سیستم سلامت کشور و منطقه داشته باشد.

مراجع

- [1] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020.
- [2] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks.”
- [3] G. Izacard and E. Grave, “Leveraging passage retrieval with generative models for open domain question answering,” *arXiv preprint arXiv:2007.01282*, 2021.
- [4] O. A. Team, “Guardrails for language models: Mitigating hallucinations in llm outputs,” 2023. <https://openai.com/research/guardrails>.
- [5] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, “Language models are few-shot learners.”
- [6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need.”
- [7] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, N. Scales, A. Tanwani, H. Cole-Lewis, S. Pföhl, P. Payne, M. Seneviratne, P. Gamble, C. Kelly, N. Scharli, A. Chowdhery, P. Mansfield, B. A. y. Arcas, D. Webster, G. S. Corrado, Y. Matias, K. Chou, J. Gottweis, N. Tomasev, Y. Liu, A. Rajkomar, J. Barral, C. Semturs, A. Karthikesalingam, and V. Natarajan, “Large language models encode clinical knowledge.”
- [8] K. Singhal, T. Tu, J. Gottweis, R. Sayres, E. Wulczyn, L. Hou, K. Clark, S. Pföhl, H. Cole-Lewis, D. Neal, M. Schackermann, A. Wang, M. Amin, S. Lachgar, P. Mansfield, S. Prakash, B. Green, E. Dominowska, B. A. y.

- Arcas, N. Tomasev, Y. Liu, R. Wong, C. Semturs, S. S. Mahdavi, J. Barral, D. Webster, G. S. Corrado, Y. Matias, S. Azizi, A. Karthikesalingam, and V. Natarajan, "Towards expert-level medical question answering with large language models."
- [9] Z. Chen, A. H. Cano, A. Romanou, A. Bonnet, K. Matoba, F. Salvi, M. Pagliardini, S. Fan, A. Köpf, A. Mohtashami, A. Sallinen, A. Sakhaeirad, V. Swamy, I. Krawczuk, D. Bayazit, A. Marmet, S. Montariol, M.-A. Hartley, M. Jaggi, and A. Bosselut, "MEDITRON-70b: Scaling medical pretraining for large language models."
- [10] Y. Labrak, A. Bazoge, E. Morin, P.-A. Gourraud, M. Rouvier, and R. Dufour, "BioMistral: A collection of open-source pretrained large language models for medical domains."
- [11] A. K. Gururajan, E. Lopez-Cuena, J. Bayarri-Planas, A. Tormos, D. Hinjos, P. Bernabeu-Perez, A. Arias-Duart, P. A. Martin-Torres, L. Urcelay-Ganzabal, M. Gonzalez-Mallo, S. Alvarez-Napagao, E. Ayguadé-Parra, and U. C. D. Garcia-Gasulla, "Aloe: A family of fine-tuned open healthcare LLMs."
- [12] H. Kim, H. Hwang, J. Lee, S. Park, D. Kim, T. Lee, C. Yoon, J. Sohn, D. Choi, and J. Kang, "Small language models learn enhanced reasoning skills from medical textbooks."
- [13] K. Vishwanath, J. Stryker, A. Alyakin, D. A. Alber, and E. K. Oermann, "MedMobile: A mobile-sized language model with expert-level clinical capabilities."
- [14] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models."
- [15] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs."
- [16] C. Gao and S. Q. Zhang, "DLoRA: Distributed parameter-efficient fine-tuning solution for large language model."
- [17] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, and H. Wang, "Retrieval-augmented generation for large language models: A survey."
- [18] D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, S. Truitt, and J. Larson, "From local to global: A graph RAG approach to query-focused summarization."
- [19] Z. Guo, L. Xia, Y. Yu, T. Ao, and C. Huang, "LightRAG: Simple and fast retrieval-augmented generation."

- [20] G. Xiong, Q. Jin, Z. Lu, and A. Zhang, "Benchmarking retrieval-augmented generation for medicine."
- [21] I. Manes, N. Ronn, D. Cohen, R. I. Ber, Z. Horowitz-Kugler, and G. Stanovsky, "K-QA: A real-world medical q&a benchmark."
- [22] M. Ghassabi, P. Rostami, H. B. Kashani, A. Poursina, Z. Kazemi, and M. Tavakoli, "Leveraging Online Data to Enhance Medical Knowledge in a Small Persian Language Model," May 2025. arXiv:2505.16000 [cs].
- [23] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-thought prompting elicits reasoning in large language models."
- [24] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, "Self-consistency improves chain of thought reasoning in language models."
- [25] X. Li, R. Zhao, Y. K. Chia, B. Ding, S. Joty, S. Poria, and L. Bing, "Chain-of-knowledge: Grounding large language models via dynamic knowledge adapting over heterogeneous sources."
- [26] S. Yao, D. Yu, J. Zhao, I. Shafran, T. L. Griffiths, Y. Cao, and K. Narasimhan, "Tree of thoughts: Deliberate problem solving with large language models."
- [27] J. Wang, E. Shi, S. Yu, Z. Wu, C. Ma, H. Dai, Q. Yang, Y. Kang, J. Wu, H. Hu, C. Yue, H. Zhang, Y. Liu, Y. Pan, Z. Liu, L. Sun, X. Li, B. Ge, X. Jiang, D. Zhu, Y. Yuan, D. Shen, T. Liu, and S. Zhang, "Prompt engineering for healthcare: Methodologies and applications."
- [28] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, and R. Lowe, "Training language models to follow instructions with human feedback."
- [29] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, and C. Finn, "Direct preference optimization: Your language model is secretly a reward model."
- [30] K. Ethayarajh, W. Xu, N. Muennighoff, D. Jurafsky, and D. Kiela, "KTO: Model alignment as prospect theoretic optimization."
- [31] J. Hong, N. Lee, and J. Thorne, "ORPO: Monolithic preference optimization without reference model."
- [32] D. Vilares and C. Gómez-Rodríguez, "HEAD-QA: A healthcare dataset for complex reasoning."

- [33] A. Pal, L. K. Umapathi, and M. Sankarasubbu, "MedMCQA : A large-scale multi-subject multi-choice dataset for medical domain question answering."
- [34] D. Jin, E. Pan, N. Oufattole, W.-H. Weng, H. Fang, and P. Szolovits, "What disease does this patient have? a large-scale open domain question answering dataset from medical exams."
- [35] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, "Measuring massive multitask language understanding."
- [36] Q. Jin, B. Dhingra, Z. Liu, W. W. Cohen, and X. Lu, "PubMedQA: A dataset for biomedical research question answering."
- [37] H. Chen, Z. Fang, Y. Singla, and M. Dredze, "Benchmarking large language models on answering and explaining challenging medical questions."
- [38] L. Gao, J. Tow, B. Abbasi, S. Biderman, S. Black, A. DiPofi, C. Foster, L. Golding, J. Hsu, A. Le Noac'h, H. Li, K. McDonell, N. Muennighoff, C. Ociepa, J. Phang, L. Reynolds, H. Schoelkopf, A. Skowron, L. Sutawika, E. Tang, A. Thite, B. Wang, K. Wang, and A. Zou, "A framework for few-shot language model evaluation," 07 2024.
- [39] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT."
- [40] V. Aryabumi, J. Dang, D. Talupuru, S. Dash, D. Cairuz, H. Lin, B. Venkitesh, M. Smith, J. A. Campos, Y. C. Tan, K. Marchisio, M. Bartolo, S. Ruder, A. Locatelli, J. Kreutzer, N. Frosst, A. Gomez, P. Blunsom, M. Fadaee, A. Üstün, and S. Hooker, "Aya 23: Open weight releases to further multilingual progress."
- [41] J. Dang, S. Singh, D. D'souza, A. Ahmadian, A. Salamanca, M. Smith, A. Peppin, S. Hong, M. Govindassamy, T. Zhao, S. Kublik, M. Amer, V. Aryabumi, J. A. Campos, Y.-C. Tan, T. Kocmi, F. Strub, N. Grinsztajn, Y. Flet-Berliac, A. Locatelli, H. Lin, D. Talupuru, B. Venkitesh, D. Cairuz, B. Yang, T. Chung, W.-Y. Ko, S. S. Shi, A. Shukayev, S. Bae, A. Piktus, R. Castagné, F. Cruz-Salinas, E. Kim, L. Crawhall-Stein, A. Morisot, S. Roy, P. Blunsom, I. Zhang, A. Gomez, N. Frosst, M. Fadaee, B. Ermiş, A. Üstün, and S. Hooker, "Aya expanse: Combining research breakthroughs for a new multilingual frontier."
- [42] K. Zhang, S. Zeng, E. Hua, N. Ding, Z.-R. Chen, Z. Ma, H. Li, G. Cui, B. Qi, X. Zhu, X. Lv, H. Jinfang, Z. Liu, and B. Zhou, "UltraMedical: Building specialized generalists in biomedicine."
- [43] G. Team, M. Riviere, S. Pathak, P. G. Sessa, C. Hardin, S. Bhupatiraju, L. Hussenot, T. Mesnard, B. Shahriari, A. Ramé, J. Ferret, P. Liu, P. Tafti,

- A. Friesen, M. Casbon, S. Ramos, R. Kumar, C. L. Lan, S. Jerome, A. Tsitsulin, N. Vieillard, P. Stanczyk, S. Girgin, N. Momchev, M. Hoffman, S. Thakoor, J.-B. Grill, B. Neyshabur, O. Bachem, A. Walton, A. Severyn, A. Parrish, A. Ahmad, A. Hutchison, A. Abdagic, A. Carl, A. Shen, A. Brock, A. Coenen, A. Laforge, A. Paterson, B. Bastian, B. Piot, B. Wu, B. Royal, C. Chen, C. Kumar, C. Perry, C. Welty, C. A. Choquette-Choo, D. Sinopalnikov, D. Weinberger, D. Vijaykumar, D. Rogozińska, D. Herbison, E. Bandy, E. Wang, E. Noland, E. Moreira, E. Senter, E. Eltyshev, F. Visin, G. Rasskin, G. Wei, G. Cameron, G. Martins, H. Hashemi, H. Klimczak-Plucińska, H. Batra, H. Dhand, I. Nardini, J. Mein, J. Zhou, J. Svensson, J. Stanway, J. Chan, J. P. Zhou, J. Carrasqueira, J. Iljazi, J. Becker, J. Fernandez, J. v. Amersfoort, J. Gordon, J. Lipschultz, J. Newlan, J.-y. Ji, K. Mohamed, K. Badola, K. Black, K. Millican, K. McDonell, K. Nguyen, K. Sodhia, K. Greene, L. L. Sjoesund, L. Usui, L. Sifre, L. Heuermann, L. Lago, L. McNealus, L. B. Soares, L. Kilpatrick, L. Dixon, L. Martins, M. Reid, M. Singh, M. Iverson, M. Görner, M. Velloso, M. Wirth, M. Davidow, M. Miller, M. Rahtz, M. Watson, M. Risdal, M. Kazemi, M. Moynihan, M. Zhang, M. Kahng, M. Park, M. Rahman, M. Khatwani, N. Dao, N. Bardoliwalla, N. Devanathan, N. Dumai, N. Chauhan, O. Wahltinez, P. Botarda, P. Barnes, P. Barham, P. Michel, P. Jin, P. Georgiev, P. Culliton, P. Kuppala, R. Comanescu, R. Merhej, R. Jana, R. A. Rokni, R. Agarwal, R. Mullins, S. Saadat, S. M. Carthy, S. Cogan, S. Perrin, S. M. R. Arnold, S. Krause, S. Dai, S. Garg, S. Sheth, S. Ronstrom, S. Chan, T. Jordan, T. Yu, T. Eccles, T. Hennigan, T. Kocisky, T. Doshi, V. Jain, V. Yadav, V. Meshram, V. Dharmadhikari, W. Barkley, W. Wei, W. Ye, W. Han, W. Kwon, X. Xu, Z. Shen, Z. Gong, Z. Wei, V. Cotruta, P. Kirk, A. Rao, M. Giang, L. Peran, T. Warkentin, E. Collins, J. Barral, Z. Ghahramani, R. Hadsell, D. Sculley, J. Banks, A. Dragan, S. Petrov, O. Vinyals, J. Dean, D. Hassabis, K. Kavukcuoglu, C. Farabet, E. Buchatskaya, S. Borgeaud, N. Fiedel, A. Joulin, K. Kenealy, R. Dadashi, and A. Andreev, “Gemma 2: Improving Open Language Models at a Practical Size,” Oct. 2024. arXiv:2408.00118 [cs].
- [44] G. Team, A. Kamath, J. Ferret, S. Pathak, N. Vieillard, R. Merhej, S. Perrin, T. Matejovicova, A. Ramé, M. Rivière, L. Rouillard, T. Mesnard, G. Cideron, J.-b. Grill, S. Ramos, E. Yvinec, M. Casbon, E. Pot, I. Penchev, G. Liu, F. Visin, K. Kenealy, L. Beyer, X. Zhai, A. Tsitsulin, R. Busa-Fekete, A. Feng, N. Sachdeva, B. Coleman, Y. Gao, B. Mustafa, I. Barr, E. Parisotto, D. Tian, M. Eyal, C. Cherry, J.-T. Peter, D. Sinopalnikov, S. Bhupatiraju, R. Agarwal, M. Kazemi, D. Malkin, R. Kumar, D. Vilar, I. Brusilovsky, J. Luo, A. Steiner, A. Friesen, A. Sharma, A. Sharma, A. M. Gilady, A. Goedeckemeyer, A. Saade, A. Feng, A. Kolesnikov, A. Bendebury, A. Abdagic, A. Vadi, A. György, A. S. Pinto, A. Das, A. Bapna, A. Miech, A. Yang, A. Paterson, A. Shenoy, A. Chakrabarti, B. Piot, B. Wu, B. Shahrari, B. Petrini, C. Chen, C. L. Lan, C. A. Choquette-Choo, C. J. Carey, C. Brick, D. Deutsch, D. Eisen-

- bud, D. Cattle, D. Cheng, D. Paparas, D. S. Sreepathihalli, D. Reid, D. Tran, D. Zelle, E. Noland, E. Huizenga, E. Kharitonov, F. Liu, G. Amirkhanyan, G. Cameron, H. Hashemi, H. Klimczak-Plucińska, H. Singh, H. Mehta, H. T. Lehri, H. Hazimeh, I. Ballantyne, I. Szpektor, I. Nardini, J. Pouget-Abadie, J. Chan, J. Stanton, J. Wieting, J. Lai, J. Orbay, J. Fernandez, J. Newlan, J.-y. Ji, J. Singh, K. Black, K. Yu, K. Hui, K. Vodrahalli, K. Greff, L. Qiu, M. Valentine, M. Coelho, M. Ritter, M. Hoffman, M. Watson, M. Chaturvedi, M. Moynihan, M. Ma, N. Babar, N. Noy, N. Byrd, N. Roy, N. Momchev, N. Chauhan, N. Sachdeva, O. Bunyan, P. Botarda, P. Caron, P. K. Rubenstein, P. Culliton, P. Schmid, P. G. Sessa, P. Xu, P. Stanczyk, P. Tafti, R. Shivanna, R. Wu, R. Pan, R. Rokni, R. Willoughby, R. Vallu, R. Mullins, S. Jerome, S. Smoot, S. Girgin, S. Iqbal, S. Reddy, S. Sheth, S. Pöder, S. Bhatnagar, S. R. Panyam, S. Eiger, S. Zhang, T. Liu, T. Yacovone, T. Liechty, U. Kalra, U. Evci, V. Misra, V. Roseberry, V. Feinberg, V. Kolesnikov, W. Han, W. Kwon, X. Chen, Y. Chow, Y. Zhu, Z. Wei, Z. Egyed, V. Cotruta, M. Giang, P. Kirk, A. Rao, K. Black, N. Babar, J. Lo, E. Moreira, L. G. Martins, O. Sanseviero, L. Gonzalez, Z. Gleicher, T. Warkentin, V. Mirrokni, E. Senter, E. Collins, J. Barral, Z. Ghahramani, R. Hadsell, Y. Matias, D. Sculley, S. Petrov, N. Fiedel, N. Shazeer, O. Vinyals, J. Dean, D. Hassabis, K. Kavukcuoglu, C. Farabet, E. Buchatskaya, J.-B. Alayrac, R. Anil, Dmitry, Lepikhin, S. Borgeaud, O. Bachem, A. Joulin, A. Andreev, C. Hardin, R. Dadashi, and L. Hussenot, “Gemma 3 Technical Report,” Mar. 2025.
- [45] OpenAI, S. Agarwal, L. Ahmad, J. Ai, S. Altman, A. Applebaum, E. Arbus, R. K. Arora, Y. Bai, B. Baker, H. Bao, B. Barak, A. Bennett, T. Bertao, N. Brett, E. Brevdo, G. Brockman, S. Bubeck, C. Chang, K. Chen, M. Chen, E. Cheung, A. Clark, D. Cook, M. Dukhan, C. Dvorak, K. Fives, V. Fomenko, T. Garipov, K. Georgiev, M. Glaese, T. Gogineni, A. Goucher, L. Gross, K. G. Guzman, J. Hallman, J. Hehir, J. Heidecke, A. Helyar, H. Hu, R. Huet, J. Huh, S. Jain, Z. Johnson, C. Koch, I. Kofman, D. Kundel, J. Kwon, V. Kyrylov, E. Y. Le, G. Leclerc, J. P. Lennon, S. Lessans, M. Lezcano-Casado, Y. Li, Z. Li, J. Lin, J. Liss, Lily, Liu, J. Liu, K. Lu, C. Lu, Z. Martinovic, L. McCallum, J. McGrath, S. McKinney, A. McLaughlin, S. Mei, S. Mostovoy, T. Mu, G. Myles, A. Neitz, A. Nichol, J. Pachocki, A. Paino, D. Palmie, A. Pantuliano, G. Parascandolo, J. Park, L. Pathak, C. Paz, L. Peran, D. Pimenov, M. Pokrass, E. Proehl, H. Qiu, G. Raila, F. Raso, H. Ren, K. Richardson, D. Robinson, B. Rotsted, H. Salman, S. Sanjeev, M. Schwarzer, D. Sculley, H. Sikchi, K. Simon, K. Singhal, Y. Song, D. Stuckey, Z. Sun, P. Tillet, S. Toizer, F. Tsimpourlas, N. Vyas, E. Wallace, X. Wang, M. Wang, O. Watkins, K. Weil, A. Wendling, K. Whinnery, C. Whitney, H. Wong, L. Yang, Y. Yang, M. Yasunaga, K. Ying, W. Zaremba, W. Zhan, C. Zhang, B. Zhang, E. Zhang, and S. Zhao, “gpt-oss-120b & gpt-oss-20b Model Card,” Aug. 2025. arXiv:2508.10925 [cs].